Università degli Studi di Napoli Parthenope

Scuola Interdipartimentale delle Scienze, dell'Ingegneria e della Salute

Dipartimento di Scienze e Tecnologie

Corso di Laurea Triennale in Informatica

EXPLAINABLE AI PER IL PEOPLE ANALYTICS: METODI E FRAMEWORK PER MODELLI INTERPRETABILI

Relatore
Prof. Emanuel Di Nardo

Correlatore
Prof. Pasquale De Luca

Candidato
Mattia Danisi
Matricola: 0124002281

ANNO ACCADEMICO 2025/2026

A ...

Sommario

Il presente lavoro affronta il tema dell'Explainable Artificial Intelligence (XAI) applicata alla People Analytics, con l'obiettivo di mostrare come le tecniche di spiegabilità possano rendere operativamente utili le previsioni di un modello di machine learning nel contesto della gestione del turnover aziendale.

Dopo aver inquadrato la People Analytics nella sua evoluzione storica e aver evidenziato i limiti degli approcci tradizionali alla retention, la tesi analizza i fondamenti teorici di tre framework esplicativi — SHAP, LIME e le spiegazioni controfattuali (Alibi) — discutendone proprietà formali, ambiti di applicazione e limiti. L'analisi teorica è integrata da un caso studio illustrativo condotto sul dataset IBM HR Employee Attrition, nel quale un modello XGBoost è addestrato a prevedere il rischio di abbandono e le tre tecniche sono applicate alle medesime istanze per confrontarne il contributo informativo.

I risultati mostrano che i tre framework non sono alternativi ma complementari: SHAP fornisce un'attribuzione fondata e coerente con la decisione del modello, LIME traduce la spiegazione in regole accessibili a un utente non tecnico, e il controfattuale indica le condizioni minime sotto cui la predizione cambierebbe, abilitando il passaggio dalla diagnosi all'intervento. La convergenza o divergenza dei tre metodi sulle stesse istanze consente al responsabile HR di calibrare il proprio livello di fiducia nella segnalazione e di decidere se e come intervenire. La conclusione principale è che la capacità predittiva acquista valore operativo solo quando è accompagnata da un ecosistema esplicativo capace di rispondere simultaneamente alle domande *perché*, *come* e *cosa fare*.

Abstract

This thesis addresses the application of Explainable Artificial Intelligence (XAI) to People Analytics, demonstrating how explainability techniques can transform machine learning predictions into actionable insights for employee turnover management.

After situating People Analytics within its historical evolution and highlighting the limitations of traditional retention approaches, the work analyzes the theoretical foundations of three explanatory frameworks — SHAP, LIME, and counterfactual explanations (Alibi) — discussing their formal properties, domains of application, and limitations. The theoretical analysis is complemented by an illustrative case study on the IBM HR Employee Attrition dataset, where an XGBoost model is trained to predict attrition risk and the three techniques are applied to the same instances for comparative evaluation.

Results show that the three frameworks are not alternatives but complements: SHAP provides a grounded attribution consistent with the model's decision, LIME translates the explanation into rules accessible to a non-technical user, and counterfactuals identify the minimal conditions under which the prediction would change, enabling the transition from diagnosis to intervention. The convergence or divergence of the three methods on the same instances allows the HR manager to calibrate trust in the alert and decide whether and how to act. The main conclusion is that predictive power gains operational value only when accompanied by an explanatory ecosystem capable of simultaneously answering the questions *why*, *how*, and *what to do*.

Indice

Sommario **ii**

1 Introduzione **1**

1.1 Contesto e motivazione 1

1.2 Dal reattivo al predittivo: la People Analytics 2

1.3 Dalla previsione all'azione: il limite dei modelli *black box* 2

1.4 Obiettivi della tesi 3

2 Quadro teorico **5**

2.1 People Analytics e turnover 5

2.1.1 Definizione ed evoluzione della People Analytics 5

2.1.2 Fattori di attrition 6

2.1.3 Limiti degli approcci tradizionali e vantaggi dei dati strutturati 8

2.2 Machine Learning per la previsione del turnover 9

2.3 Explainable AI (XAI) 9

2.3.1 Definizione di interpretabilità 9

2.3.2 Interpretabilità ed esplicabilità 10

2.3.3 Caratteristiche di una buona spiegazione 11

2.3.4 Quando l'interpretabilità è necessaria e quando no 12

2.3.5 L'effetto Rashomon 14

2.3.6 SHAP (SHapley Additive exPlanations) 15

2.3.7 LIME (Local Interpretable Model-agnostic Explanations) . 18

2.3.8 Spiegazioni controfattuali (Alibi CounterfactualProto) . . . 21

2.3.9 Confronto teorico SHAP e LIME 27

3 Caso studio illustrativo **29**

3.1 Dataset e setup 29

3.1.1 Il dataset IBM HR Attrition 29

3.1.2 Preprocessing 30

3.1.3 Strategia di bilanciamento e tuning degli iperparametri . . 32

3.2 Performance del modello 33
3.2.1 Ottimizzazione della soglia 34
3.3 Spiegazioni SHAP 35
3.3.1 Importanza globale delle feature 35
3.3.2 Tre casi locali: vero positivo, falso positivo, falso negativo . 37
3.4 Spiegazioni LIME 40
3.4.1 Importanza globale aggregata 40
3.4.2 Spiegazioni locali sui tre casi 41
3.4.3 Confronto sinottico 43
3.5 Analisi controfattuale (Alibi) 44
3.5.1 Configurazione dell'explainer 44
3.5.2 Dipendente 214: una lettura operativa coerente 44
3.5.3 Dipendente 223: un controfattuale che rivela bias del modello 46
3.5.4 Leve azionabili vs fattori immutabili 47
3.6 Dashboard 47

4 Discussione **48**
4.1 Sintesi dei risultati 48
4.2 Limiti del caso studio 49
4.3 Implicazioni per la pratica HR 51
4.3.1 Dal segnale all'azione: il workflow XAI-assistito 51
4.3.2 Rischi dell'adozione: algorithm aversion e automation bias 52
4.3.3 Bias algoritmici e fairness 53
4.3.4 Quadro normativo: GDPR e AI Act 53
4.3.5 Human-in-the-loop come requisito di governance 54

5 Conclusioni e sviluppi futuri **56**
5.1 Sviluppi futuri 57

A Appendici **58**
A.1 Elenco completo delle feature del dataset IBM HR 58
A.2 Spazio degli iperparametri e configurazione del modello 60

Bibliografia **61**

Ringraziamenti **64**

Capitolo 1

Introduzione

1.1 Contesto e motivazione

Nell'economia attuale, il costo del turnover rappresenta un onere finanziario e operativo significativo per le aziende. Secondo Boushey e Glynn, *There Are Significant Business Costs to Replacing Employees*, negli Stati Uniti il costo medio del turnover si colloca in un intervallo compreso tra il 20% e il 50% dello stipendio annuale del dipendente uscente. Per figure di alto profilo all'interno dell'organico aziendale, come dirigenti o ruoli *high-skilled*, tale onere può arrivare fino al 213%. Il report Work Institute, *2024 Retention Report: Employee Turnover Insights and Trends in 2023* ha stimato che, nel 2023, le aziende statunitensi hanno speso approssimativamente 900 miliardi di dollari soltanto per la sostituzione dei dipendenti che hanno abbandonato volontariamente il posto di lavoro. Uno studio su piccola scala presentato in Kuhn e Yu, "How Costly Is Turnover? Evidence from Retail", relativo a piccole aziende del settore retail, ha quantificato il costo diretto della produttività persa in $1.840 (approssimativamente 9,6 giorni lavorativi); tale stima, tuttavia, esclude i costi di acquisizione, di formazione e tutti i *soft cost* legati al nuovo candidato. La situazione risulta analoga nel continente europeo. Price, *The Cost of Employee Turnover* stima in £30.614 (∼122% dello stipendio annuo) il costo medio per sostituire un dipendente, in un'azienda del Regno Unito, con retribuzione annua superiore a £25.000, così suddiviso:

- costo di acquisizione e assunzione: ∼£5.400;
- produttività persa durante il periodo di avviamento di 28 settimane: ∼£25.182.

CIPD, *The True Cost of Hiring in 2025* riporta stime pressoché analoghe, con un costo di assunzione di circa £6.125 e un costo totale, nelle prime 52 settimane, pari a £63.000. In Francia, Elevo HR, *Le vrai coût du turn-over et de la perte*

des talents quantifica il costo di sostituzione in un valore compreso tra 6 e 9 mesi dello stipendio annuo del dipendente da rimpiazzare.

1.2 Dal reattivo al predittivo: la People Analytics

A fronte dei costi evidenziati nella sezione precedente, diventa indispensabile per le aziende spostare il proprio approccio da uno reattivo — fondato su *exit interview* e indagini successive all'abbandono — a uno predittivo e *data-driven*, orientato a identificare per tempo i dipendenti a rischio e a intervenire con azioni mirate di *retention*. Le fondamenta di questo approccio risiedono nella People Analytics (anche detta HR o worforce analytics), che Isson e Harriott, *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent* definiscono come l'integrazione di fonti di dati eterogenee, provenienti sia dall'interno sia dall'esterno dell'azienda, funzionali a rispondere e ad agire su domande di business strategiche relative al capitale umano di un'organizzazione. In questa direzione, il report Poynton et al., *2026 Global Human Capital Trends. From tensions to tipping points: Choosing the human advantage* evidenzia uno spostamento dell'attenzione da un paradigma *tech-centric* a uno *human-centric*: la tecnologia è, per sua natura, replicabile, mentre capacità prettamente umane come l'intuito, la creatività e il senso del giudizio non lo sono. Nel medesimo report si rileva, inoltre, che il 67% dei leader intervistati ritiene che l'avvento dell'IA abbia segnato un punto di svolta, in cui la velocità e l'agilità sono divenute il principale vantaggio competitivo.

1.3 Dalla previsione all'azione: il limite dei modelli *black box*

Uno degli obiettivi centrali della People Analytics consiste nel trasformare l'insieme eterogeneo di dati raccolti in previsioni azionabili sui comportamenti dei dipendenti, a partire dal rischio di abbandono volontario dell'azienda. Per raggiungere tale scopo le organizzazioni ricorrono a modelli di *machine learning* in grado di cogliere relazioni non lineari tra le variabili e di restituire, per ciascun dipendente, una stima probabilistica del rischio di *attrition* Schweyer, "Predictive analytics and artificial intelligence in people management".

Tali modelli, tuttavia, pagano la loro elevata capacità predittiva con un costo significativo in termini di trasparenza: operano, di fatto, come vere e proprie *scatole nere* (*black box*), fornendo in output un punteggio di rischio senza esplicitare le

ragioni che lo sostengono. Nel contesto HR questa opacità è tutt'altro che innocua. In primo luogo, un manager difficilmente agisce sulla base di una previsione che non è in grado di comprendere e giustificare ai propri superiori o al diretto interessato, fenomeno noto in letteratura come *algorithm aversion* Dietvorst, Simmons e Massey, "Algorithm aversion: people erroneously avoid algorithms after seeing them err." In secondo luogo, l'informazione che un dipendente è ad alto rischio di dimissione risulta di scarsa utilità operativa se non si conoscono le leve su cui intervenire per trattenerlo. Infine, le decisioni automatizzate che riguardano le persone sollevano questioni etiche e normative di primo piano: il GDPR, all'art. 22, riconosce agli interessati il diritto a non essere sottoposti a decisioni basate unicamente su trattamenti automatizzati e a ricevere una spiegazione significativa della logica sottesa *Regolamento (UE) 2016/679 del Parlamento Europeo e del Consiglio — Articolo 22: Processo decisionale automatizzato relativo alle persone fisiche, compresa la profilazione*.

Proprio per rispondere a queste esigenze si è sviluppata la *Explainable Artificial Intelligence* (XAI), un insieme di tecniche che permettono di rendere ispezionabili le decisioni dei modelli complessi senza sacrificarne la capacità predittiva. Come sarà approfondito nel capitolo successivo, la XAI si propone come elemento di raccordo tra le *performance* dei modelli di ultima generazione e la trasparenza richiesta dagli utenti finali; trasparenza che, in ambito HR, si traduce nella necessità concreta di fornire spiegazioni intelligibili a manager non tecnici, chiamati a convertire le previsioni degli algoritmi in azioni concrete sul capitale umano.

1.4 Obiettivi della tesi

Alla luce di quanto esposto, il presente lavoro si propone di mostrare come le tecniche di *Explainable Artificial Intelligence* possano costituire uno strumento concreto a supporto della People Analytics, con il fine ultimo di incrementare la *retention* del personale. L'ipotesi di fondo è che la capacità predittiva di un modello di *machine learning*, per quanto accurata, acquisti reale valore operativo solo quando è accompagnata da spiegazioni intelligibili: soltanto comprendendo le ragioni di una previsione e individuando le leve su cui intervenire, un responsabile HR può trasformare un segnale di rischio di abbandono in un'azione mirata di *retention*.

In coerenza con la natura compilativa del lavoro, l'obiettivo generale si articola in tre obiettivi specifici:

- fornire un quadro teorico organico sull'applicazione della XAI alla previsione del *turnover*, collocandola all'interno della più ampia evoluzione della People Analytics e dei vincoli normativi che regolano le decisioni automatizzate in ambito HR;

- presentare e confrontare tre tra i principali *framework* di XAI — SHAP, LIME e le spiegazioni controfattuali (Alibi) — analizzandone i fondamenti teorici, le proprietà, gli ambiti di applicazione e i limiti;

- illustrare, attraverso un caso studio condotto sul *dataset* IBM HR Employee Attrition, come i tre *framework* rispondano a domande differenti poste dal responsabile HR e discutere quale approccio esplicativo risulti più adeguato al contesto, sia per interpretare le decisioni del modello sia per individuare interventi concreti finalizzati alla *retention*.

Coerentemente con l'impianto compilativo, il caso studio presentato nel Capitolo 3 non ha finalità sperimentali: esso funge da banco di prova illustrativo per i concetti sviluppati nel quadro teorico e mira a rendere tangibile il contributo che la XAI può offrire al passaggio dalla previsione all'azione nel contesto HR.

Capitolo 2

Quadro teorico

2.1 People Analytics e turnover

2.1.1 Definizione ed evoluzione della People Analytics

La *People Analytics*, nota anche come *Talent Analytics* o *Workforce Analytics*, può essere definita come l'integrazione sistematica di fonti di dati eterogenee, provenienti sia dall'interno sia dall'esterno dell'organizzazione, finalizzata a rispondere a domande strategiche di business relative al capitale umano di un'impresa. A differenza della reportistica HR tradizionale, che si limita a descrivere ciò che è già accaduto, la People Analytics si concentra sulla previsione dei risultati futuri e sulla creazione di valore strategico attraverso l'analisi sistematica del comportamento dei dipendenti Isson e Harriott, *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent*.

L'interesse verso la misurazione sistematica del lavoro umano non costituisce un fenomeno recente. Le radici storiche della disciplina possono essere rintracciate all'inizio del XX secolo, con lo *Scientific Management* di Frederick Taylor (1911) e le prime applicazioni della psicologia industriale a opera di Hugo Münsterberg (1913), a cui si affiancò, durante la Prima Guerra Mondiale, l'adozione dei primi test mentali su larga scala per la selezione del personale militare. Un passaggio decisivo verso la quantificazione delle risorse umane si è avuto alla fine degli anni Settanta, quando Jac Fitz-enz propose le prime metriche formali per l'HR, ponendo le basi per lo sviluppo del benchmarking di settore. Negli anni Novanta, l'adozione della *Balanced Scorecard* e della sua successiva declinazione HR rese esplicito il legame tra pratiche HR e performance organizzativa, mentre a partire dalla metà degli anni Duemila la diffusione dei *Talent Management Systems* (TMS) ha consentito di automatizzare i processi HR e di archiviare in modo strutturato

i dati sui dipendenti. Soltanto intorno al 2010, infine, l'analisi predittiva ha iniziato a consolidarsi come pratica effettiva nei dipartimenti delle risorse umane, nell'ambito di un più ampio spostamento verso un'integrazione multidisciplinare di fonti dati allineate agli obiettivi strategici del vertice aziendale.

L'evoluzione contemporanea della disciplina è sospinta da un insieme di forze convergenti. Da un lato, l'esplosione dei *big data* e la diffusione di sorgenti digitali relative al lavoro hanno reso disponibile una quantità di informazioni sul talento senza precedenti, trasformandole in una potenziale leva competitiva. Dall'altro, la progressiva riduzione della permanenza media dei dipendenti presso la medesima organizzazione ha accresciuto l'urgenza di strumenti capaci di cogliere precocemente i segnali di un possibile abbandono. A queste dinamiche si aggiunge il mutato atteggiamento delle generazioni più giovani nei confronti del lavoro, che richiede forme più continue e strutturate di monitoraggio dell'*engagement*.

In questo scenario, la funzione HR si trova coinvolta in un progressivo spostamento da un paradigma tradizionale, prevalentemente reattivo e orientato alla dimensione amministrativa e *soft* della gestione del personale, a un paradigma emergente in cui la gestione del talento identifica in modo proattivo rischi e opportunità legati al capitale umano, adottando un approccio basato sull'evidenza empirica. È in questa prospettiva che la People Analytics è stata definita il "*Moneyball* delle risorse umane", in analogia con la trasformazione *data-driven* che ha investito ambiti professionali inizialmente poco permeabili all'uso strategico dei dati.

2.1.2 Fattori di attrition

L'*attrition*, ovvero l'uscita volontaria dei dipendenti dall'organizzazione, può essere ricondotta a un'interazione complessa tra condizioni di lavoro interne, pressioni del mercato esterno e caratteristiche individuali del lavoratore. La rassegna della letteratura consente di raggruppare i principali antecedenti in quattro macro-aree, utili a delineare lo spazio delle variabili su cui un modello predittivo di People Analytics è chiamato a operare Isson e Harriott, *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent*.

Un primo gruppo di determinanti attiene all'ambiente di lavoro e alle pratiche gestionali. Un carico di lavoro eccessivo, unito alla progressiva erosione dei periodi di recupero, tende ad accrescere lo stress percepito e ad aumentare sensibilmente la probabilità di abbandono nei mesi successivi. Altrettanto rilevante è la qualità della relazione con il *management*: il comportamento dei superiori diretti, in particolare all'interno di progetti di grandi dimensioni, incide in modo profondo sull'esperienza

lavorativa quotidiana e, di conseguenza, sulla permanenza organizzativa. Anche la scarsità di *feedback* strutturato sulle prestazioni e la mancanza di un riconoscimento tangibile dei risultati alimentano un progressivo disallineamento tra aspettative e percezioni, contribuendo a erodere il legame con l'organizzazione.

Un secondo gruppo di fattori riguarda la dimensione economica e lo sviluppo professionale. La percezione di un'inadeguata equità retributiva e l'assenza di prospettive credibili di crescita interna figurano fra le ragioni più frequentemente richiamate dai lavoratori che scelgono di cambiare datore di lavoro. A queste si affiancano determinanti di ordine culturale e generazionale: la letteratura sottolinea come le coorti più giovani attribuiscano un valore crescente al significato personale del lavoro, all'allineamento con la *mission* aziendale, al senso di appartenenza e alla responsabilità sociale dell'impresa Poynton et al., *2026 Global Human Capital Trends. From tensions to tipping points: Choosing the human advantage*. In assenza di una missione riconoscibile e condivisa, tali lavoratori mostrano una maggiore propensione alla mobilità. In questa stessa chiave vanno letti i mutamenti più recenti legati alla diffusione dell'intelligenza artificiale nei processi di lavoro, che ha introdotto nuovi fattori di rischio quali l'aumento dei carichi cognitivi, la riduzione dell'autonomia, un senso di isolamento dovuto alla minore collaborazione fra colleghi e l'incertezza sulla stabilità futura del proprio ruolo Poynton et al., *2026 Global Human Capital Trends. From tensions to tipping points: Choosing the human advantage*.

Una terza famiglia di antecedenti ha natura strettamente individuale. Tratti di personalità e *fit* culturale con l'organizzazione risultano fra i predittori più significativi della permanenza: una marcata discrepanza fra i valori personali del dipendente e quelli dell'impresa rappresenta infatti una delle cause più ricorrenti di *turnover* precoce. Simili variabili individuali sono notoriamente difficili da osservare per via diretta e, quando non disponibili, il loro effetto tende a essere parzialmente assorbito dalle variabili comportamentali e contrattuali registrate nei sistemi informativi HR.

Un ultimo gruppo di fattori, infine, opera dall'esterno dell'organizzazione. La presenza di mercati del lavoro competitivi, con bassi tassi di disoccupazione per i profili qualificati e offerte retributive aggressive da parte dei concorrenti, agisce come potente leva di attrazione verso l'esterno. La progressiva diffusione delle piattaforme professionali digitali, rendendo immediatamente accessibili nuove opportunità e notifiche personalizzate, ha inoltre reso la forza lavoro più reattiva ai segnali di mercato, accorciando i tempi di decisione che precedono le dimissioni.

Un elemento importante ai fini del presente lavoro riguarda l'orizzonte tem-

porale entro cui tali segnali iniziano a manifestarsi. Le evidenze disponibili suggeriscono che i primi indicatori di disimpegno compaiano in media con un anticipo compreso fra i nove e i dodici mesi rispetto alle dimissioni effettive. È proprio in questa finestra temporale che l'impiego di modelli predittivi di People Analytics assume rilevanza strategica, consentendo di identificare i dipendenti a rischio con sufficiente anticipo per attivare interventi di *retention* mirati.

2.1.3 Limiti degli approcci tradizionali e vantaggi dei dati strutturati

Nonostante la crescente disponibilità di dati sul capitale umano, una parte significativa delle decisioni relative alla gestione dei talenti continua a fondarsi sull'intuizione personale, sull'esperienza pregressa e su relazioni interpersonali difficilmente oggettivabili. La letteratura evidenzia come tale approccio, definito talvolta "basato sull'esperienza educata", risulti privo della profondità analitica necessaria per orientare scelte strategiche in contesti organizzativi complessi Isson e Harriott, *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent*.

A questa fragilità strutturale si accompagnano ulteriori limiti. I metodi tradizionali di selezione, come le interviste non strutturate, hanno mostrato un potere predittivo sulla performance lavorativa futura prossimo a quello di una scelta casuale; analogamente, criteri storicamente consolidati quali il voto di laurea o i punteggi dei test attitudinali si sono rivelati indicatori poco affidabili del rendimento effettivo. Sul versante della *retention*, gli strumenti convenzionali di ascolto organizzativo — quali le *survey* periodiche e le *exit interview* — operano in modo prevalentemente retrospettivo, registrando il disagio soltanto quando le dimissioni si sono già verificate o sono imminenti, senza offrire margini per un intervento tempestivo. Anche i canali di reclutamento più diffusi, dalle bacheche di annunci alle fiere universitarie, sono divenuti risorse generiche, accessibili a tutti i concorrenti e pertanto incapaci di conferire un vantaggio competitivo distintivo. In un simile contesto, la funzione HR rischia di essere percepita come un centro di costo a vocazione prevalentemente amministrativa e normativa, distante dalle priorità strategiche del vertice aziendale.

L'adozione di dati strutturati e di tecniche analitiche avanzate consente di superare questi limiti e di riposizionare la gestione delle risorse umane come funzione strategica. Il beneficio principale risiede nella possibilità di transitare da decisioni basate sull'aneddoto a strategie fondate su evidenze analitiche, legittimando l'HR come interlocutore credibile del *top management*. In secondo luogo, l'integrazione

di fonti dati eterogenee — dalle rilevazioni interne ai dati di mercato del lavoro, dall'analisi dei flussi digitali alle metriche di *engagement* — permette di rispondere a domande aziendali complesse in modo rapido e accurato, costruendo modelli predittivi in grado di identificare in anticipo i dipendenti a rischio di abbandono e di stimare il ritorno sull'investimento del capitale umano. A titolo illustrativo, la letteratura riporta il caso di un'organizzazione che, sostituendo i criteri di selezione basati sull'esperienza con variabili legate ai tratti di personalità, ha ottenuto una riduzione significativa del tasso di *attrition*. Infine, la disponibilità di dati longitudinali rende possibile l'applicazione al talento di modelli ispirati alla gestione del ciclo di vita del cliente, tracciando ciascun dipendente dal primo contatto con l'organizzazione fino all'eventuale uscita, così da ottimizzare le strategie di *retention* lungo l'intero percorso professionale.

È in questa transizione dall'intuizione all'evidenza che si colloca il contributo della People Analytics: una "scienza delle decisioni" applicata alle persone, analoga a quanto già avvenuto nella finanza e nel marketing.

2.2 Machine Learning per la previsione del turnover

2.3 Explainable AI (XAI)

2.3.1 Definizione di interpretabilità

L'interpretabilità nel *machine learning* è un concetto che non possiede una definizione matematica univoca, ma viene descritto attraverso prospettive complementari nella letteratura Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Una prima accezione la identifica con il grado in cui un essere umano è in grado di comprendere la causa di una decisione prodotta da un modello. Una seconda prospettiva, di natura più operativa, considera un metodo interpretabile quando un utente riesce a prevedere correttamente ed efficientemente i risultati del metodo stesso: in altri termini, quanto più il comportamento del modello risulta anticipabile, tanto maggiore è la sua interpretabilità. Una terza definizione descrive l'interpretabilità come l'atto di mappare concetti astratti, generati internamente dal modello, in una forma che sia comprensibile per l'uomo Roscher et al., "Explainable Machine Learning for Scientific Insights and Discoveries". Infine, in un'accezione più ampia, il termine può essere inteso come un concetto ombrello che racchiude l'estrazione di conoscenze rilevanti da un

modello di *machine learning*, sia per quanto riguarda le relazioni contenute nei dati, sia per quelle apprese dal modello durante l'addestramento Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

In termini comparativi, un modello si considera più interpretabile di un altro quando le sue decisioni risultano più facili da comprendere per un essere umano. Questa definizione relativa riflette il fatto che l'interpretabilità non è una proprietà binaria, bensì un continuum lungo il quale i modelli si collocano in posizioni differenti. L'obiettivo ultimo dell'interpretabilità è consentire a chi interagisce con il modello di comprendere il *perché* di determinate decisioni o previsioni, facilitando così la risoluzione di problemi che derivano da una formalizzazione necessariamente incompleta dei compiti del mondo reale Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

2.3.2 Interpretabilità ed esplicabilità

I termini *interpretability* ed *explainability* vengono frequentemente impiegati come sinonimi nella letteratura sul *machine learning*, tuttavia tra essi sussistono sfumature tecniche che meritano di essere esplicitate, nonostante l'assenza di un accordo univoco nella comunità scientifica Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Secondo la distinzione proposta da Roscher et al., l'*interpretability* riguarda la mappatura di un concetto astratto prodotto dal modello in una forma comprensibile per l'essere umano, mentre l'*explainability* rappresenta un requisito più forte, che presuppone l'interpretabilità ma richiede in aggiunta l'inserimento di un contesto supplementare capace di rendere la spiegazione pienamente significativa per il destinatario Roscher et al., "Explainable Machine Learning for Scientific Insights and Discoveries". In questa prospettiva, l'esplicabilità compie un passo ulteriore rispetto all'interpretabilità, collocando la comprensione del modello all'interno di un quadro di riferimento più ampio.

Sul piano terminologico, il termine *explanation* (spiegazione) viene generalmente riservato ai metodi locali, il cui scopo è rendere conto di una singola previsione specifica, piuttosto che del comportamento complessivo del modello Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Nella pratica, tuttavia, la distinzione tra i due concetti tende a sfumare. L'approccio pragmatico suggerito dalla letteratura consiste nel trattarli come un termine ombrello che racchiude l'insieme delle tecniche finalizzate all'estrazione di conoscenza rilevante da un modello, sia riguardo alle relazioni presenti nei

dati sia a quelle apprese durante l'addestramento Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

2.3.3 Caratteristiche di una buona spiegazione

La ricerca nelle scienze cognitive e sociali ha messo in luce che una spiegazione efficace per l'essere umano non coincide necessariamente con una descrizione completa e tecnicamente esaustiva di tutte le cause di un fenomeno, ma deve possedere proprietà specifiche che riflettono il modo in cui le persone elaborano e valutano le informazioni Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

La prima proprietà è la **contrastività**. Gli esseri umani raramente si interrogano sulle cause di un evento in termini assoluti; tendono piuttosto a chiedersi perché sia accaduto un certo esito *invece di un altro*. Il ragionamento è intrinsecamente controfattuale: chi riceve il rifiuto di una richiesta non desidera conoscere tutti i fattori generali che hanno condotto alla decisione, bensì quelli che avrebbero dovuto essere diversi affinché l'esito fosse favorevole.

La seconda proprietà è la **selettività**. Le persone non si aspettano un elenco completo di tutte le cause che hanno contribuito a un risultato, ma preferiscono spiegazioni brevi che individuino al massimo due o tre fattori principali, anche quando la realtà sottostante è considerevolmente più complessa.

La terza proprietà riguarda la dimensione **sociale** della spiegazione. Ogni spiegazione si inserisce in un'interazione tra chi la formula e chi la riceve: il suo contenuto, il livello di dettaglio e il registro comunicativo devono adattarsi al destinatario e al contesto in cui avviene lo scambio. Una spiegazione rivolta a un esperto del dominio differirà in modo sostanziale da quella destinata a un interlocutore privo di competenze tecniche.

La quarta proprietà è la **focalizzazione sull'anormale**. Gli esseri umani tendono a considerare particolarmente convincenti le spiegazioni che si concentrano su cause rare o insolite. Quando un evento inatteso ha influenzato il risultato, esso viene percepito come la causa principale, anche qualora altri fattori ordinari abbiano esercitato un peso analogo.

La quinta proprietà è la **veridicità**: una spiegazione dovrebbe essere il più possibile fedele alla realtà. Tuttavia, nella valutazione umana, la selettività e il contrasto risultano spesso più importanti della completezza. Un'approssimazione parziale ma chiara viene generalmente preferita a una ricostruzione esaustiva ma incomprensibile.

La sesta proprietà è la **coerenza con le credenze precedenti**. Le persone tendono a svalutare o ignorare le spiegazioni che contraddicono le proprie convinzioni pregresse, un fenomeno riconducibile al *bias* di conferma. Una spiegazione efficace è pertanto quella che si armonizza con il modello mentale e le conoscenze pregresse del destinatario, pur introducendo elementi informativi nuovi.

Infine, in assenza di eventi anormali, vengono considerate buone le spiegazioni **generali**, ovvero quelle applicabili a molti casi simili e fondate su relazioni probabilisticamente solide.

Queste proprietà hanno implicazioni dirette per la progettazione di metodi di *Explainable AI*: affinché una spiegazione algoritmica risulti realmente utile, non è sufficiente che sia accurata dal punto di vista del modello, ma deve essere formulata in modo da rispettare i meccanismi cognitivi e sociali attraverso i quali gli esseri umani comprendono e valutano le informazioni Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

2.3.4 Quando l'interpretabilità è necessaria e quando no

L'esigenza di interpretabilità nel *machine learning* nasce dal fatto che una singola metrica di performance, come l'accuratezza, fornisce una descrizione incompleta della maggior parte dei compiti del mondo reale. Per affrontare problemi complessi, non è sufficiente conoscere *cosa* è stato previsto: è spesso indispensabile comprendere il *perché* Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Le ragioni per cui l'interpretabilità risulta necessaria possono essere ricondotte a sei ambiti principali. Il primo riguarda il **miglioramento e il *debugging* del modello**: l'interpretabilità consente di identificare se un modello ha appreso scorciatoie spurie — i cosiddetti *Clever Hans predictors* — ovvero se si affida a caratteristiche non causali per formulare le proprie previsioni. Essa permette inoltre di individuare errori nell'ingegneria delle *feature* e di generare ipotesi per il loro perfezionamento.

Il secondo ambito concerne la **giustificazione e la responsabilità**. In numerosi settori, fra cui quello bancario e quello sanitario, è necessario fornire agli *stakeholder* una giustificazione delle decisioni algoritmiche. L'interpretabilità consente di contestare decisioni errate e di verificare che il modello operi in conformità con le normative vigenti; in ambito europeo, il Regolamento generale sulla protezione dei dati (GDPR) riconosce il diritto dell'interessato a non essere sottoposto a decisioni basate unicamente su un trattamento automatizzato e a ottenere informazioni significative sulla logica utilizzata *Regolamento*

(UE) 2016/679 del Parlamento Europeo e del Consiglio — Articolo 22: Processo decisionale automatizzato relativo alle persone fisiche, compresa la profilazione.

Il terzo ambito attiene alla **sicurezza e alla gestione del rischio**. In contesti ad alto impatto è essenziale accertarsi che il sistema abbia appreso rappresentazioni prive di errori sistematici; comprendere il processo decisionale del modello aiuta a prevedere casi limite e a garantire la robustezza complessiva del sistema.

Il quarto ambito riguarda il **rilevamento dei *bias* e la *fairness***. I modelli possono ereditare pregiudizi dai dati di addestramento, producendo decisioni discriminatorie nei confronti di gruppi sottorappresentati. L'interpretabilità funge da strumento di *debugging* per individuare distorsioni che non verrebbero rilevate dalla sola funzione di perdita.

Il quinto ambito è quello della **scoperta scientifica**. Numerose discipline impiegano il *machine learning* per estrarre conoscenze da grandi insiemi di dati; l'interpretabilità consente di trasformare il modello stesso in una fonte di comprensione dei fenomeni, rendendo esplicite le relazioni tra le variabili.

Il sesto ambito, infine, riguarda la **curiosità umana e l'accettazione sociale**. Gli esseri umani possiedono il desiderio di trovare un significato nel mondo e di armonizzare le contraddizioni; un sistema capace di spiegare il proprio comportamento favorisce la fiducia e facilita l'integrazione degli algoritmi nella pratica quotidiana Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Esistono tuttavia situazioni in cui l'interpretabilità non è necessaria o può risultare persino controproducente. In **ambienti a basso rischio**, dove un errore del modello non comporta conseguenze rilevanti, l'assenza di spiegazioni non costituisce un problema. Analogamente, per **problemi ampiamente studiati e consolidati**, nei quali si è accumulata sufficiente esperienza pratica e il sistema opera in modo affidabile, il beneficio marginale dell'interpretabilità è limitato. In alcuni casi, l'interpretabilità può essere intenzionalmente evitata per **prevenire la manipolazione del sistema**: se i criteri decisionali di un modello fossero interamente trasparenti, gli utenti potrebbero alterare strategicamente i propri dati per ottenere un risultato favorevole, senza che la loro condizione reale sia mutata. Questo rischio è particolarmente concreto quando il modello si basa su variabili *proxy* che correlano con il risultato senza esserne la causa diretta Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

In sintesi, la necessità di interpretabilità emerge quando la formalizzazione del problema è incompleta e la sola previsione non è sufficiente a risolvere pienamente il

compito nel mondo reale. Se il compito è ben definito, sicuro e privo di implicazioni rilevanti per le persone coinvolte, l'interpretabilità può legittimamente passare in secondo piano.

2.3.5 L'effetto Rashomon

L'effetto Rashomon nel *machine learning* designa la situazione in cui esistono molteplici modelli che presentano prestazioni predittive comparabili, ma forniscono interpretazioni diverse e potenzialmente incompatibili dei dati sottostanti Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Il termine trae origine dall'omonimo film di Akira Kurosawa (1950), nel quale quattro testimoni narrano versioni differenti del medesimo evento: ciascuna ricostruzione spiega i fatti in modo altrettanto plausibile, eppure le versioni risultano inconciliabili fra loro.

In ambito modellistico, questo fenomeno solleva sfide rilevanti per l'interpretabilità. In primo luogo, la **molteplicità dei modelli** implica che diversi algoritmi o configurazioni possano raggiungere la medesima accuratezza basandosi tuttavia su relazioni differenti tra le *feature* e la variabile obiettivo. In secondo luogo, tale molteplicità genera un'**incertezza nell'interpretazione**: se due modelli funzionano in modo equivalente dal punto di vista predittivo, ma raccontano storie diverse su come i dati interagiscono, non è chiaro quale di queste rifletta in modo più fedele la realtà del fenomeno osservato. Infine, l'effetto Rashomon complica la **scoperta di conoscenze**: per utilizzare un modello come surrogato della realtà, è necessario assumere che la sua struttura rispecchi il mondo; l'esistenza di modelli alternativi ed equivalenti mina questa assunzione, poiché ciascuno di essi potrebbe suggerire conclusioni diverse sullo stesso fenomeno Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

L'effetto Rashomon evidenzia dunque come una buona performance predittiva non garantisca un'unica spiegazione corretta, complicando il compito di chi cerca di comprendere i meccanismi sottostanti ai dati attraverso l'analisi dei modelli. Questa considerazione è particolarmente rilevante nel contesto della presente tesi, dove tre diversi framework di *Explainable AI* vengono applicati al medesimo modello: le eventuali discordanze tra le spiegazioni prodotte non devono essere interpretate necessariamente come un limite degli strumenti, ma possono riflettere la pluralità intrinseca delle interpretazioni compatibili con le stesse evidenze empiriche.

2.3.6 SHAP (SHapley Additive exPlanations)

Il framework SHAP (*SHapley Additive exPlanations*), proposto da Lundberg e Lee, rappresenta un approccio unificato all'interpretazione delle previsioni dei modelli di *machine learning*, fondato sui valori di Shapley della teoria dei giochi cooperativi Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions".

Fondamenti nella teoria dei giochi cooperativi

I valori di Shapley, originariamente formulati nell'ambito della teoria dei giochi cooperativi, risolvono il problema dell'attribuzione equa del merito tra i partecipanti a un gioco collaborativo. SHAP adatta questo concetto al contesto predittivo, rappresentando ogni previsione del modello come un gioco in cui le *feature* sono i giocatori che cooperano per spostare la previsione dal valore medio di base (la media delle previsioni sull'intero dataset) al valore finale calcolato per una specifica istanza Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions".

Per ciascuna previsione, SHAP assegna a ogni *feature* un valore di attribuzione ϕ_i che quantifica il contributo marginale di quella *feature* al risultato. Il calcolo si basa sul cambiamento dell'aspettativa condizionata del modello quando la *feature* viene inclusa in un dato sottoinsieme: concretamente, il valore di Shapley di una *feature* corrisponde alla media ponderata dei suoi contributi marginali, calcolata su tutte le possibili combinazioni di *feature* Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions".

Proprietà formali

SHAP identifica una classe di metodi denominati *metodi di attribuzione additiva delle feature* e dimostra che esiste un'unica soluzione all'interno di questa classe che soddisfa simultaneamente tre proprietà fondamentali Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions":

- **Accuratezza locale (*Local Accuracy*).** La somma delle attribuzioni delle singole *feature* (ϕ_i) e del valore di base (ϕ_0) deve essere uguale all'output del modello originale $f(x)$ per l'input considerato. Questa proprietà garantisce che la spiegazione sia completa: nessuna parte della previsione rimane non attribuita.

- **Assenza (*Missingness*).** Se una *feature* è assente dall'input originale, il suo impatto attribuito deve essere nullo. Questa proprietà assicura che non vengano assegnati contributi a informazioni non disponibili.

- **Consistenza (*Consistency*).** Se un modello viene modificato in modo tale che il contributo marginale di una *feature* aumenti o rimanga invariato, indipendentemente dagli altri input, l'attribuzione di quella *feature* non deve diminuire. Questa proprietà impedisce che le spiegazioni si comportino in modo controintuitivo al variare del modello.

L'unicità della soluzione che soddisfa congiuntamente queste tre proprietà costituisce il principale argomento teorico a favore di SHAP rispetto ad altri metodi di attribuzione: le spiegazioni prodotte non sono una scelta arbitraria tra molte possibili, ma l'unica attribuzione coerente con i principi di equità ereditati dalla teoria dei giochi Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions".

TreeExplainer: ottimizzazione per modelli ad albero

Il calcolo esatto dei valori di Shapley richiede la valutazione di 2^M sottoinsiemi di *feature*, dove M è il numero totale di variabili, risultando computazionalmente proibitivo per la maggior parte delle applicazioni reali. Per i modelli basati su *ensemble* di alberi decisionali — fra cui XGBoost, impiegato nel caso studio della presente tesi — è stato sviluppato l'algoritmo *Tree SHAP*, che sfrutta la struttura degli alberi per calcolare i valori SHAP esatti in tempo polinomiale Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

L'algoritmo utilizza due procedure ricorsive, denominate Extend e Unwind, che operano durante la discesa lungo l'albero. Extend tiene traccia, a ogni nodo, della proporzione di sottoinsiemi di *feature* che fluiscono in ciascun ramo, distinguendo tra i casi in cui una *feature* è presente (e segue il percorso dell'istanza osservata) e quelli in cui è assente (per i quali viene calcolata una media ponderata dei rami, pesata in base alla copertura dei dati di addestramento). Unwind interviene nei nodi foglia per annullare selettivamente l'effetto di ciascuna *feature* e isolare il suo contributo specifico secondo i pesi di Shapley. Questo approccio consente di tracciare simultaneamente tutti i possibili sottoinsiemi in un unico passaggio attraverso l'albero, riducendo la complessità computazionale da $O(TLM \cdot 2^M)$ a $O(TLD^2)$, dove T è il numero di alberi, L il numero di foglie e D la profondità massima Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

Un aspetto rilevante riguarda il trattamento delle *feature* assenti durante il calcolo. *Tree SHAP* distingue due modalità di stima dell'aspettativa condizionata. La modalità *tree path-dependent*, utilizzata per impostazione predefinita, sfrutta

la copertura dei nodi dell'albero per pesare i rami quando una *feature* è assente, rispecchiando la distribuzione dei dati appresa dal modello e tenendo conto implicitamente delle correlazioni tra le variabili. La modalità *interventional* impone invece l'indipendenza tra le *feature*, integrando l'output del modello su un insieme di campioni di riferimento. La prima modalità risulta più fedele al comportamento effettivo del modello sui dati reali, ma può attribuire importanza a *feature* correlate anche in assenza di un impatto causale diretto; la seconda è più appropriata quando si desidera un'interpretazione di tipo causale Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

Dalle spiegazioni locali a quelle globali

Sebbene SHAP sia concepito come un metodo di spiegazione locale, orientato alla singola previsione, l'aggregazione dei valori SHAP su un intero dataset consente di ricavare una visione globale dell'importanza delle *feature* Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

Lo strumento principale per questa transizione è il *summary plot*, un grafico a sciame (*beeswarm*) in cui ogni punto rappresenta un'istanza del dataset: la posizione sull'asse orizzontale indica l'impatto della *feature* (il valore SHAP), mentre il colore codifica il valore della *feature* stessa. Questa rappresentazione consente di visualizzare simultaneamente la magnitudo, la prevalenza e la direzione degli effetti di ciascuna variabile. Il *dependence plot* offre un livello di dettaglio ulteriore, rappresentando il valore di una *feature* sull'asse orizzontale e il corrispondente valore SHAP sull'asse verticale: la dispersione verticale tra punti con lo stesso valore della *feature* rivela la presenza di interazioni con altre variabili Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

Tree SHAP consente inoltre di calcolare i *valori di interazione SHAP*, basati sull'indice di interazione di Shapley. Questi valori producono, per ogni previsione, una matrice di attribuzioni in cui la diagonale contiene gli effetti principali di ciascuna *feature* e gli elementi fuori diagonale rappresentano gli effetti di interazione puri tra coppie di variabili. Rispetto ai valori SHAP standard, che condensano effetto principale e interazioni in un unico numero, i valori di interazione consentono di separare le due componenti, rendendo visibili pattern che altrimenti rimarrebbero nascosti Lundberg, Erion et al., "Explainable AI for Trees: From Local Explanations to Global Understanding".

Limiti

Nonostante le solide basi teoriche, il framework SHAP presenta alcune criticità che è opportuno considerare. La principale riguarda la **complessità computazionale**: anche con le ottimizzazioni di *Tree SHAP*, il calcolo dei valori di Shapley per modelli non arborei richiede approssimazioni basate su campionamento (*Kernel SHAP*), che necessitano di un numero elevato di valutazioni per produrre stime stabili Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions". Un secondo limite concerne l'**assunzione di indipendenza delle *feature***: molte delle approssimazioni computazionali, tra cui *Kernel SHAP*, presuppongono l'indipendenza o la linearità del modello per semplificare il calcolo delle aspettative condizionate. In presenza di *feature* fortemente correlate, questa assunzione può condurre a spiegazioni che non riflettono fedelmente il comportamento del modello Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions". Infine, poiché la maggior parte dei modelli non è in grado di gestire pattern arbitrari di valori mancanti, SHAP deve **approssimare** l'assenza di una *feature* integrando sulla sua distribuzione marginale, introducendo un livello di approssimazione rispetto al valore teorico puro Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions".

2.3.7 LIME (Local Interpretable Model-agnostic Explanations)

Il framework LIME (*Local Interpretable Model-agnostic Explanations*), proposto da Ribeiro, Singh e Guestrin, adotta una strategia complementare rispetto a SHAP: anziché derivare le attribuzioni da un fondamento assiomatico, approssima localmente il comportamento di un modello complesso mediante un modello surrogato interpretabile, tipicamente lineare, addestrato nell'intorno dell'istanza da spiegare Ribeiro, Singh e Guestrin, ""Why Should I Trust You?": Explaining the Predictions of Any Classifier".

Perturbazione locale e modello surrogato lineare

L'intuizione alla base di LIME è che, sebbene il confine decisionale di un modello complesso possa essere globalmente non lineare, in un intorno sufficientemente ristretto di una singola osservazione esso può essere approssimato con ragionevole fedeltà da un modello più semplice. Il metodo opera in tre fasi Ribeiro, Singh e Guestrin, ""Why Should I Trust You?": Explaining the Predictions of Any Classifier".

Nella prima fase, LIME genera un insieme di campioni sintetici perturbati nell'intorno dell'istanza da spiegare. Per i dati tabulari, la perturbazione avviene estraendo valori da una distribuzione normale la cui media e deviazione standard sono ricavate dalla corrispondente *feature* nel dataset di addestramento Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Un aspetto rilevante di questa procedura è che il campionamento viene effettuato indipendentemente per ciascuna *feature*, ignorando le eventuali correlazioni presenti nei dati reali: ciò può generare combinazioni di valori poco plausibili, un limite che il metodo condivide con altre tecniche di perturbazione Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Nella seconda fase, ciascun campione perturbato viene sottoposto al modello originale per ottenerne la previsione, che funge da etichetta per l'addestramento del surrogato. A ogni campione viene inoltre assegnato un peso proporzionale alla sua prossimità rispetto all'istanza di interesse, calcolato mediante un kernel esponenziale:

$$\pi_x(z) = \exp\left(-\frac{D(x,z)^2}{\sigma^2}\right)$$

dove D è una funzione di distanza calcolata sui dati normalizzati e σ è l'ampiezza del kernel, che determina la dimensione dell'intorno locale Ribeiro, Singh e Guestrin, "'"Why Should I Trust You?": Explaining the Predictions of Any Classifier". Campioni più vicini all'istanza originale ricevono un peso maggiore e influenzano in misura prevalente il modello surrogato, mentre campioni lontani contribuiscono in modo trascurabile.

Nella terza fase, LIME addestra un modello interpretabile g — tipicamente un modello lineare sparso — sul dataset pesato di campioni perturbati, minimizzando la funzione obiettivo:

$$\xi(x) = \underset{g \in G}{\operatorname{argmin}}\ L(f, g, \pi_x) + \Omega(g)$$

dove $L(f, g, \pi_x)$ misura l'infedeltà del surrogato g rispetto al modello originale f nella località definita da π_x, e $\Omega(g)$ è un termine di regolarizzazione che penalizza la complessità del modello, ad esempio il numero di *feature* con coefficiente non nullo Ribeiro, Singh e Guestrin, "'"Why Should I Trust You?": Explaining the Predictions of Any Classifier". Il risultato è un insieme ristretto di *feature* con i relativi pesi, che rappresentano l'importanza locale di ciascuna variabile per la previsione analizzata.

Un aspetto qualificante di LIME è la sua natura *model-agnostic*: il metodo

tratta il modello originale come una scatola nera, interagendo con esso esclusivamente attraverso coppie input-output, senza richiedere accesso alla struttura interna, ai gradienti o ai pesi del modello Ribeiro, Singh e Guestrin, “"Why Should I Trust You?": Explaining the Predictions of Any Classifier”. Questa proprietà garantisce l'applicabilità del framework a qualsiasi classe di modelli, ma comporta al contempo una dipendenza dalla qualità della rappresentazione interpretabile: se quest'ultima non è sufficientemente espressiva, LIME non sarà in grado di catturare aspetti rilevanti del comportamento del modello.

Fedeltà locale

La qualità di una spiegazione LIME è valutata in termini di *fedeltà locale*, ovvero la capacità del modello surrogato di riprodurre fedelmente le previsioni del modello originale nell'intorno dell'istanza analizzata Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Tale fedeltà è misurata dalla componente di perdita L nella funzione obiettivo: un valore basso indica che il surrogato lineare approssima adeguatamente il comportamento locale della *black box*, mentre un valore elevato segnala che l'approssimazione lineare è inadeguata in quel punto dello spazio delle *feature* e che la spiegazione risultante è poco affidabile.

La fedeltà locale è intrinsecamente legata a due scelte progettuali che l'utente deve compiere prima di generare la spiegazione Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. La prima è l'**ampiezza del kernel** σ, che controlla la dimensione dell'intorno locale: un valore ridotto restringe l'analisi a un vicinato molto prossimo all'istanza, aumentando la fedeltà ma riducendo la quantità di informazione disponibile per il surrogato; un valore elevato amplia il vicinato, rischiando tuttavia di includere regioni dello spazio in cui il modello presenta un comportamento sostanzialmente diverso. La seconda è il **numero di *feature*** K ammesse nel surrogato: un valore di K più alto consente al modello lineare di catturare dinamiche più complesse, accrescendo potenzialmente la fedeltà, ma al costo di una minore immediatezza interpretativa Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Entrambe le scelte sono tipicamente definite in via euristica e la letteratura evidenzia come la determinazione dell'ampiezza ottimale del kernel costituisca un problema aperto Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Limiti

Il framework LIME presenta alcune criticità rilevanti che ne circoscrivono l'affidabilità e l'ambito di applicazione.

Il limite più discusso è l'**instabilità delle spiegazioni**. Poiché i campioni perturbati vengono generati tramite un processo stocastico, esecuzioni ripetute del metodo sulla medesima istanza possono produrre spiegazioni differenti, sia nel *ranking* delle *feature* sia nei valori dei coefficienti Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Questa variabilità, particolarmente accentuata quando il numero di campioni è limitato o il confine decisionale locale presenta irregolarità, mina la riproducibilità delle spiegazioni e ne complica l'impiego in contesti decisionali dove la coerenza è un requisito.

Un secondo limite riguarda la **sensibilità alla parametrizzazione**. Come evidenziato nella sezione precedente, la scelta dell'ampiezza del kernel e del numero di *feature* influenza in modo sostanziale il contenuto della spiegazione. In assenza di criteri formali per la calibrazione di questi parametri, valori diversi possono condurre a interpretazioni divergenti della medesima previsione Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Il terzo limite attiene alla natura stessa dell'**approssimazione lineare**. Se il modello originale presenta interazioni non lineari complesse anche in un intorno ristretto dell'istanza, un surrogato lineare non sarà in grado di catturarle fedelmente, producendo spiegazioni che semplificano eccessivamente il comportamento del modello Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

Un ultimo limite, specifico per i dati tabulari, riguarda l'**assunzione di indipendenza** nel campionamento delle perturbazioni. Poiché i valori di ciascuna *feature* vengono estratti indipendentemente dalla distribuzione marginale, i campioni sintetici possono rappresentare combinazioni di valori irrealistiche, con potenziali effetti sulla qualità delle previsioni ottenute dal modello originale e, di conseguenza, sulla fedeltà della spiegazione Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*.

2.3.8 Spiegazioni controfattuali (Alibi CounterfactualProto)

Le spiegazioni controfattuali costituiscono un approccio concettualmente distinto rispetto a SHAP e LIME. Mentre questi ultimi tentano di ricostruire, con strumenti diversi, il contributo delle *feature* alla previsione di un modello, il controfattuale

rinuncia a spiegare la logica interna della *black box* e si concentra su un'unica domanda: *quali sono le modifiche minime da apportare all'istanza affinché la previsione cambi?* Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". Il fondamento concettuale è la nozione di *closest possible world*, ovvero il mondo possibile più vicino all'istanza osservata in cui il modello produrrebbe l'esito desiderato Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". Tale formulazione è coerente con la tesi secondo cui le spiegazioni umane sono intrinsecamente *contrastive*: non si spiega perché si è verificato un evento in assoluto, bensì perché esso si sia verificato al posto di un esito atteso alternativo Miller, "Explanation in Artificial Intelligence: Insights from the Social Sciences".

Da questa impostazione discendono tre proprietà qualificanti. Il controfattuale è *model-agnostic*, poiché interagisce con il modello originale esclusivamente attraverso coppie input-output, senza richiederne la struttura interna Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". È *locale*, poiché si riferisce alla singola decisione di un'istanza specifica e non al comportamento globale del modello. È *orientato all'azione* (*actionable*), poiché non si limita a descrivere ciò che il modello ha fatto, ma indica concretamente quali variabili il soggetto potrebbe modificare per conseguire un esito diverso in futuro Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". Questa natura prescrittiva rende i controfattuali particolarmente rilevanti in contesti decisionali ad alto impatto, nei quali la possibilità per l'interessato di comprendere e contestare la decisione costituisce un requisito sostanziale Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR".

Formulazione di Wachter et al.

La formalizzazione più diffusa delle spiegazioni controfattuali è quella proposta da Wachter, Mittelstadt e Russell Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". Dato un modello f_w, un'istanza originale x_i e un target desiderato y', il controfattuale x' è la soluzione del problema di ottimizzazione:

$$\arg\min_{x'} \max_{\lambda} \ \lambda \left(f_w(x') - y'\right)^2 + d(x_i, x')$$

Il primo termine penalizza la distanza tra la previsione del controfattuale e il target desiderato, imponendo la *validità* della soluzione; il secondo termine $d(x_i, x')$ è una funzione di distanza che misura quanto x' si discosti dall'istanza originale, imponendo la *prossimità* Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". Il parametro λ bilancia i due obiettivi ed è incrementato iterativamente fino al raggiungimento di una soluzione con predizione sufficientemente prossima a y'.

Una scelta progettuale rilevante riguarda la funzione di distanza d. Wachter et al. suggeriscono l'adozione della norma L_1, pesata per la deviazione assoluta mediana (MAD) delle singole *feature*, in luogo della norma L_2 Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". La motivazione è duplice. Da un lato, la ponderazione per MAD normalizza le variabili rispetto alla loro variabilità empirica, evitando che *feature* con scale numeriche differenti dominino la misura. Dall'altro, la norma L_1 tende a produrre soluzioni *sparse*, ovvero a concentrare i cambiamenti su un numero ridotto di variabili anziché distribuirli uniformemente su molte, come farebbe invece la norma L_2 Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". La sparsity è considerata una proprietà qualificante per l'interpretabilità umana: la memoria di lavoro gestisce efficacemente solo un numero limitato di elementi simultaneamente, e una spiegazione che indichi poche leve d'intervento risulta nettamente più comprensibile di una che ne elenchi molte Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR".

CounterfactualProto: guida tramite prototipi di classe

Il metodo originario presenta un limite noto: ottimizzando soltanto validità e prossimità, esso tende a generare controfattuali che superano il confine decisionale del modello ma non necessariamente risiedono in regioni dello spazio delle *feature* plausibili rispetto alla distribuzione dei dati reali Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes". Il risultato può essere una spiegazione formalmente valida ma realisticamente implausibile, di scarsa utilità come guida all'azione.

Per affrontare questa criticità, Van Looveren e Klaise propongono *CounterfactualProto*, un metodo *model-agnostic* implementato nella libreria Alibi che introduce nel processo di ottimizzazione una guida esplicita verso la distribuzione

della classe target Van Looveren e Klaise, “Interpretable Counterfactual Explanations Guided by Prototypes”. L’intuizione consiste nell’impiegare un **prototipo di classe**, ovvero una rappresentazione tipica delle istanze appartenenti alla classe desiderata, come attrattore che orienta le perturbazioni verso una regione *in-distribution*.

La funzione di perdita di CounterfactualProto si compone di più termini, ciascuno associato a un obiettivo specifico Van Looveren e Klaise, “Interpretable Counterfactual Explanations Guided by Prototypes”. Un **termine di predizione** L_{pred} incoraggia il modello ad associare all’istanza perturbata una classe diversa da quella originale. Una **distanza di tipo *elastic net***, combinazione delle norme L_1 e L_2, regola simultaneamente la sparsity e l’entità complessiva del cambiamento. Un **termine prototipo** L_{proto} minimizza la distanza tra il controfattuale e il prototipo della classe target, forzando la soluzione verso una zona dello spazio delle *feature* interpretabile e coerente con i dati osservati. Un ulteriore **termine *autoencoder*** L_{AE}, opzionale, penalizza i controfattuali situati lontano dal *manifold* dei dati di addestramento mediante l’errore di ricostruzione di un autoencoder.

La costruzione del prototipo può avvenire in due modi alternativi, a seconda della rappresentazione disponibile Van Looveren e Klaise, “Interpretable Counterfactual Explanations Guided by Prototypes”. Nella variante basata su **autoencoder**, il prototipo di ciascuna classe è definito come la codifica media, nello spazio latente dell’encoder, delle K istanze di quella classe più vicine all’istanza originale; l’ottimizzazione avviene dunque in uno spazio compresso. Nella variante basata su **k-d tree**, in assenza di un encoder addestrato, per ciascuna classe viene costruito un k-d tree sulle istanze di addestramento e il prototipo è identificato come l’elemento più vicino all’istanza originale nello spazio delle *feature* originarie. La prima variante si dimostra più efficace su dati ad alta dimensionalità come le immagini, mentre la seconda è adatta a dati tabulari o al caso in cui non si disponga di un autoencoder preaddestrato Van Looveren e Klaise, “Interpretable Counterfactual Explanations Guided by Prototypes”.

L’introduzione del termine prototipo apporta due vantaggi rispetto alla formulazione originaria. In primo luogo, migliora la *plausibilità* delle spiegazioni: anziché limitarsi a superare il confine decisionale, l’ottimizzazione spinge attivamente la soluzione verso il centro della classe target, producendo controfattuali che somigliano a istanze tipiche e realistiche Van Looveren e Klaise, “Interpretable Counterfactual Explanations Guided by Prototypes”. In secondo luogo, accelera la *convergenza* dell’ottimizzazione fornendo una direzione di ricerca informata; nei modelli *black box*, in cui i gradienti del modello originale non sono direttamente disponibili e

devono essere stimati numericamente, tale informazione aggiuntiva consente di omettere il termine L_{pred} e riduce in misura rilevante il costo computazionale Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes".

Proprietà desiderabili

La letteratura identifica un insieme di proprietà che un controfattuale di qualità dovrebbe soddisfare Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes"; Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". La **validità** richiede che la previsione del modello sull'istanza controfattuale corrisponda alla classe target. La **prossimità** richiede che il cambiamento rispetto all'istanza originale sia minimo, coerentemente con la nozione di *mondo possibile più vicino*. La **sparsity** richiede che siano modificate poche *feature*, per favorire la comprensibilità della spiegazione da parte di un utente non esperto. La **plausibilità**, o *in-distribution-ness*, richiede che il controfattuale giaccia in prossimità della distribuzione dei dati di addestramento, e in particolare della sottodistribuzione della classe target. La **diversità** richiede che, quando esistono più percorsi controfattuali, ne venga restituito un insieme variegato, così da offrire all'utente alternative distinte. Infine, l'**actionability** richiede che i cambiamenti suggeriti riguardino variabili effettivamente modificabili dall'utente; in pratica ciò si ottiene vincolando durante l'ottimizzazione le variabili immutabili ai loro valori originari Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes".

Queste proprietà non sono simultaneamente massimizzabili e la loro composizione richiede un compromesso, tipicamente governato dagli iperparametri della funzione di perdita.

Limiti

Le spiegazioni controfattuali presentano alcune criticità che ne circoscrivono l'affidabilità operativa.

Il primo limite, di natura strutturale, è la **non unicità**. Per una medesima istanza possono esistere numerosi controfattuali validi, che differiscono sia nelle *feature* modificate sia nell'entità delle variazioni: la scelta dipende dalla funzione di distanza adottata e dagli iperparametri dell'ottimizzazione Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes"; Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black

Box: Automated Decisions and the GDPR". Questa molteplicità rende la nozione stessa di "spiegazione corretta" intrinsecamente soggettiva e può complicarne l'impiego in contesti nei quali è richiesta una giustificazione univoca.

Un secondo limite è la **sensibilità agli iperparametri**. CounterfactualProto dipende dalla calibrazione di diversi pesi — tra cui il peso della sparsity, il peso del termine prototipo e il numero di vicini utilizzato per la costruzione del prototipo — la cui scelta influenza in modo sostanziale l'esito della spiegazione; l'individuazione di valori appropriati è un'attività onerosa e priva di criteri formali generali Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes".

Un terzo limite riguarda la **gestione di variabili categoriche e immutabili**. Per le *feature* categoriche non esiste una nozione naturale di distanza, e CounterfactualProto ricorre a rappresentazioni *embedding* basate su metriche specifiche, al costo di un'ulteriore complessità metodologica Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes". Gli algoritmi standard, inoltre, non distinguono autonomamente tra variabili modificabili e variabili che non lo sono per ragioni logiche, etiche o legali: in assenza di vincoli espliciti il metodo può generare controfattuali che suggeriscono modifiche a variabili quali età, genere o etnia, producendo spiegazioni inutilizzabili e potenzialmente discriminatorie Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR"; Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by Prototypes".

Un quarto limite concerne il rischio di **controfattuali non azionabili** per ragioni causali. La formulazione standard assume implicitamente l'indipendenza delle variabili, mentre nella realtà il cambiamento di una *feature* può presupporre o comportare il cambiamento di altre a essa causalmente collegate: in assenza di un modello causale esplicito, il controfattuale può suggerire modifiche che, pur minimizzando la funzione di perdita, risultano logicamente o praticamente irrealizzabili Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR".

Un ultimo limite è specifico di CounterfactualProto e consiste in un **trade-off tra sparsity e plausibilità**. La guida verso il prototipo di classe avvicina la soluzione a istanze tipiche della classe target e ne aumenta la plausibilità, ma tende a produrre controfattuali meno sparsi rispetto a quelli ottenuti minimizzando unicamente la distanza L_1: l'obiettivo di somigliare a un esempio reale della classe target richiede, in genere, l'aggiustamento di più *feature* simultaneamente Van Looveren e Klaise, "Interpretable Counterfactual Explanations Guided by

Prototypes". La scelta tra massimizzare la sparsity o la plausibilità è dunque una decisione progettuale che dipende dal contesto applicativo.

2.3.9 Confronto teorico SHAP e LIME

SHAP e LIME condividono l'obiettivo di attribuire a ciascuna *feature* un peso che rifletta il suo contributo a una specifica previsione, ma vi giungono per vie metodologicamente distinte: il primo deriva le proprie attribuzioni da un quadro assiomatico radicato nella teoria dei giochi cooperativi, mentre il secondo costruisce empiricamente un surrogato lineare locale nell'intorno dell'istanza da spiegare Lundberg e Lee, "A Unified Approach to Interpreting Model Predictions"; Ribeiro, Singh e Guestrin, ""Why Should I Trust You?": Explaining the Predictions of Any Classifier". Le conseguenze di questa differenza si riflettono su più dimensioni operative, che la Tabella 2.1 sintetizza in forma sinottica lungo i sei assi individuati come rilevanti nelle sezioni precedenti.

Le evidenze empiriche raccolte in un'analisi comparativa dei metodi additivi di spiegazione locale confermano il quadro delineato sul versante computazionale: per i modelli ad albero, *Tree SHAP* risulta nettamente più efficiente di LIME sia in bassa sia in alta dimensionalità, mentre il costo di LIME si mantiene pressoché indipendente dalla classe del modello sottostante ma cresce linearmente con il numero di *feature* e con il numero di campioni perturbati richiesti per ottenere spiegazioni stabili Doumard et al., "A Comparative Study of Additive Local Explanation Methods Based on Feature Influences".

Sul piano pratico, le due famiglie rispondono dunque a esigenze parzialmente diverse. Nel contesto della presente tesi, in cui il modello predittivo è un *ensemble* di alberi (XGBoost), *Tree SHAP* offre attribuzioni esatte, deterministiche e computazionalmente trattabili, e costituisce il riferimento metodologico primario per le spiegazioni locali. LIME svolge in questo quadro una funzione complementare: la sua natura *model-agnostic* e la forma lineare del surrogato forniscono una seconda lettura della medesima previsione, utile a valutarne la robustezza e a mettere in luce eventuali discordanze, riconducibili alla pluralità di letture compatibili con uno stesso modello già evocata discutendo l'effetto Rashomon.

Tabella 2.1: Confronto sinottico tra SHAP e LIME lungo sei dimensioni rilevanti per l'applicazione pratica.

Dimensione	**SHAP**	**LIME**
Ambito	Nativamente locale, con un'aggregazione verso una vista globale supportata dal framework attraverso *summary plot* e valori di interazione.	Strettamente locale; una vista globale è ottenibile soltanto tramite aggregazione ex post (ad esempio la media del valore assoluto dei pesi) priva di un fondamento teorico analogo.
Fedeltà	Fedeltà locale esatta per costruzione: l'assioma di *Local Accuracy* impone $\sum_i \phi_i + \phi_0 = f(x)$.	Fedeltà locale approssimata, misurata dalla componente di perdita L; degrada quando il confine decisionale è non lineare anche nell'intorno.
Stabilità	*Tree SHAP* è deterministico, poiché calcola i valori di Shapley in forma esatta; *Kernel SHAP*, fondato sul campionamento, condivide la stessa instabilità di LIME.	Stocastico per natura: esecuzioni ripetute sulla medesima istanza possono produrre *ranking* e coefficienti differenti.
Velocità	*Tree SHAP* è polinomiale ($O(TLD^2)$) e mantiene tempi pressoché costanti al crescere del numero di *feature*, risultando significativamente più efficiente di LIME sui modelli ad albero.	Costo lineare nel numero di *feature* e dominato da N valutazioni del modello originale; la variabilità tra classi di modelli è trascurabile, ma il numero di inferenze richieste rende il metodo oneroso in alta dimensionalità.
Interpretabilità	Attribuzione additiva, con valori ϕ_i espressi nella medesima unità dell'output del modello; la scomposizione della previsione è esaustiva.	Coefficienti di un modello lineare sparso definito sulla rappresentazione interpretabile; leggibili come regole semplici, ma privi di garanzie formali di completezza.
Dipendenza dal modello	Offre varianti *model-agnostic* (*Kernel SHAP*) e varianti *model-specific* ottimizzate (*Tree SHAP* per *ensemble* di alberi).	Pienamente *model-agnostic*: il modello è interrogato esclusivamente come oracolo input-output, senza alcuna assunzione sulla sua struttura interna.

Capitolo 3

Caso studio illustrativo

Il presente capitolo applica i concetti introdotti nel Capitolo 2 a un caso studio concreto, costruito sul dataset pubblico *IBM HR Employee Attrition*. L'obiettivo non è produrre un contributo sperimentale originale, ma mostrare in modo operativo come i tre framework discussi — SHAP, LIME e controfattuali Alibi — si comportino quando applicati allo stesso modello e alle stesse istanze. La coerenza del protocollo sperimentale è dunque funzionale a un confronto qualitativo tra i diversi tipi di spiegazione, non a una valutazione quantitativa delle prestazioni del modello.

3.1 Dataset e setup

3.1.1 Il dataset IBM HR Attrition

Il dataset è costituito da 1470 record, ciascuno relativo a un dipendente, descritti da 35 variabili di natura eterogenea (anagrafiche, retributive, di ruolo, di soddisfazione e di tenure). La variabile target è `Attrition`, binaria, che indica se il dipendente ha lasciato l'azienda. La distribuzione del target è fortemente sbilanciata: 1233 dipendenti (83,9%) risultano rimasti in azienda e 237 (16,1%) hanno abbandonato, come illustrato in Figura 3.1. Tale sbilanciamento condiziona tanto la scelta della metrica di valutazione quanto la strategia di bilanciamento in fase di training.

L'analisi esplorativa preliminare ha prodotto due osservazioni utili alla contestualizzazione dei risultati successivi. La prima riguarda la relazione tra età e abbandono: come mostrato in Figura 3.2, la distribuzione dell'età nel gruppo di dipendenti in uscita è spostata verso valori inferiori, suggerendo che i profili più giovani presentino una propensione relativa maggiore al turnover. La seconda osservazione riguarda la matrice di correlazione tra le feature nu-

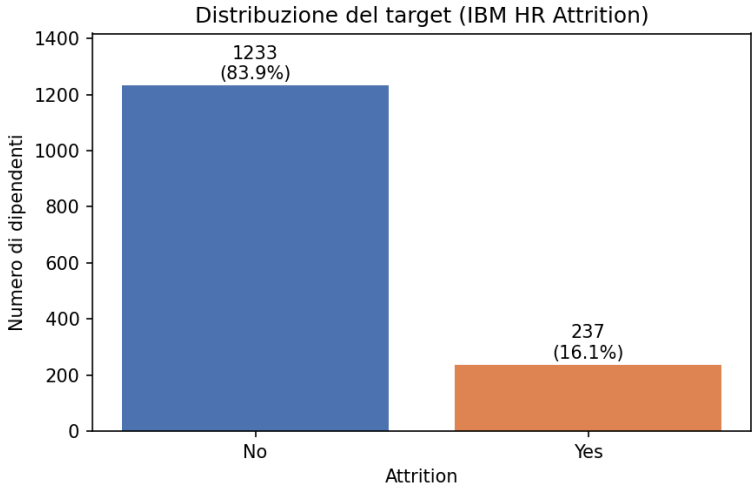

Figura 3.1: Distribuzione del target `Attrition`: il dataset è fortemente sbilanciato, con una classe positiva (dipendenti che hanno abbandonato) pari al 16,1% del totale.

meriche (Figura 3.3): emerge un blocco di forti correlazioni tra le variabili di tenure (`YearsAtCompany`, `YearsInCurrentRole`, `YearsSinceLastPromotion`, `YearsWithCurrManager`), coerenti con il fatto di misurare tutte dimensioni temporali legate alla permanenza nell'organizzazione. Una correlazione elevata è presente anche tra `JobLevel`, `MonthlyIncome` e `TotalWorkingYears`, aspetto rilevante per l'interpretazione delle spiegazioni locali: SHAP e LIME potrebbero attribuire quote di importanza a feature che, dal punto di vista causale, sono manifestazioni del medesimo costrutto sottostante.

3.1.2 Preprocessing

Il preprocessing è stato mantenuto volutamente minimale per evitare di introdurre trasformazioni che ostacolino l'interpretabilità delle spiegazioni locali. In particolare:

- sono state rimosse le feature costanti o identificative (`EmployeeCount`, `Over18`, `StandardHours`, `EmployeeNumber`), prive di potere discriminante;
- il target `Attrition` è stato codificato come binario (`Yes` $\mapsto$ 1, `No` $\mapsto$ 0);
- le variabili categoriche sono state trasformate mediante one-hot encoding con `drop_first=True`, per evitare la collinearità perfetta della codifica dummy;
- le variabili numeriche sono state lasciate nella loro scala originale, poiché XGBoost, basandosi su split binari degli alberi, non richiede standardizzazione.

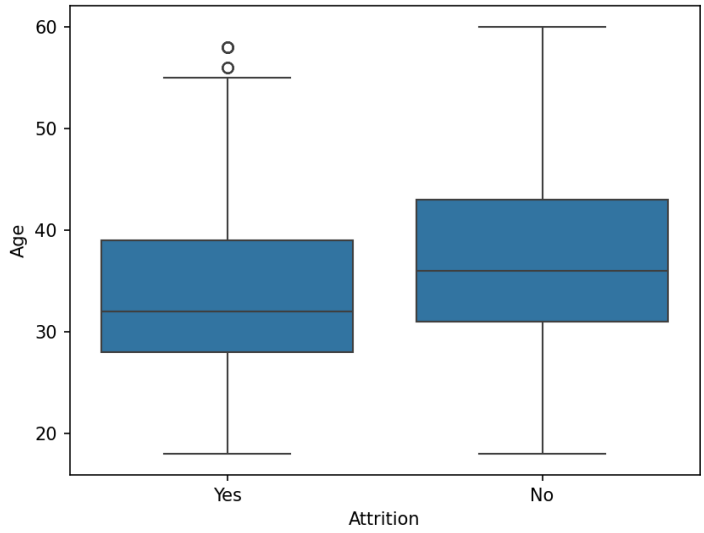

Figura 3.2: Distribuzione dell'età rispetto al target: la mediana dei dipendenti in uscita risulta inferiore rispetto a quella di chi è rimasto, indicando una maggiore propensione all'abbandono tra i profili più giovani.

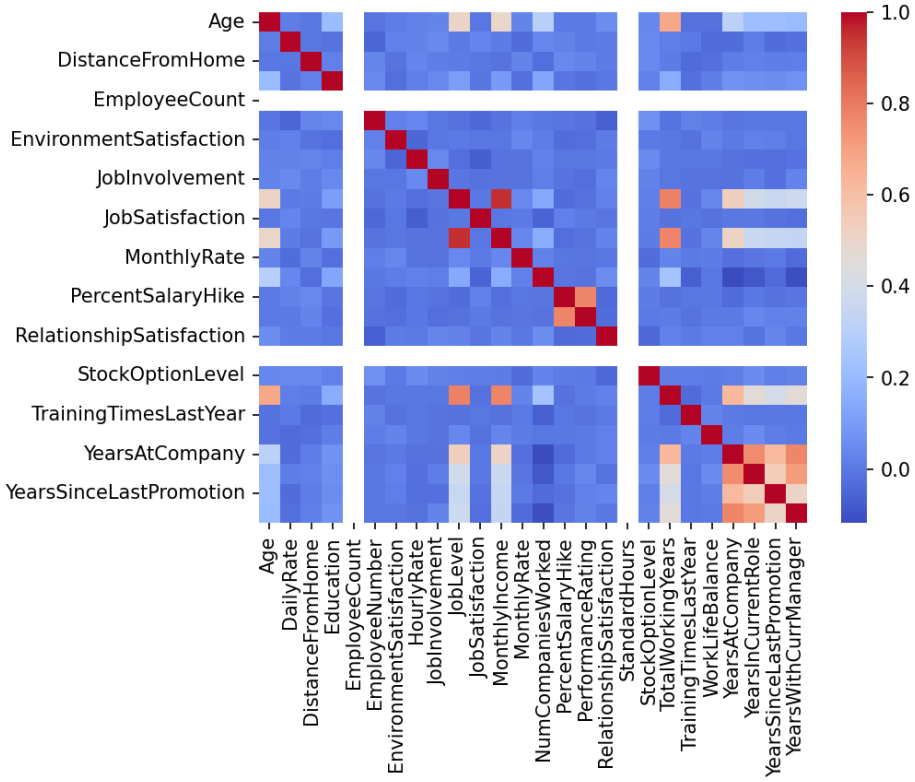

Figura 3.3: Heatmap di correlazione tra le feature numeriche. Sono evidenti i blocchi di alta correlazione tra le variabili di tenure e tra `JobLevel`, `MonthlyIncome` e `TotalWorkingYears`.

A valle di queste operazioni il numero di feature passa da 35 a 44, rimanendo compatibile con un training efficiente e con la leggibilità delle spiegazioni locali. Il dataset è stato quindi suddiviso in train e test con proporzione 80/20, stratificando rispetto al target e fissando `random_state=42` per garantire la riproducibilità.

3.1.3 Strategia di bilanciamento e tuning degli iperparametri

Date le caratteristiche del dataset, l'indicatore di prestazione principale è l'*F1-score* sulla classe positiva, che bilancia precision e recall e risulta più informativo dell'accuracy in presenza di classi sbilanciate. Sono state confrontate due strategie di bilanciamento:

- **SMOTE** (Synthetic Minority Over-sampling Technique), inserito all'interno di una pipeline `imblearn` in modo da essere applicato solo sui fold di training all'interno della cross-validation, evitando data leakage;
- **scale_pos_weight**, parametro nativo di XGBoost che aumenta il peso degli errori sulla classe positiva nella funzione di loss, calibrato come rapporto tra le frequenze delle due classi sul train.

Entrambe le strategie sono state accoppiate a una `RandomizedSearchCV` con 150 iterazioni, `StratifiedKFold` a 5 fold e scoring `f1`. Lo spazio di ricerca degli iperparametri, identico nelle due configurazioni, è riportato in forma compatta in Tabella 3.1 e in forma estesa in appendice A.2.

Tabella 3.1: Spazio di ricerca degli iperparametri di XGBoost (sintesi).

Iperparametro	Valori esplorati
`n_estimators`	100, 200, 300, 500, 700
`max_depth`	3, 4, 5, 6, 7, 8
`learning_rate`	0.01, 0.03, 0.05, 0.08, 0.1, 0.15
`subsample`	0.6, 0.7, 0.8, 0.9, 1.0
`colsample_bytree`	0.5, 0.6, 0.7, 0.8, 0.9, 1.0
`min_child_weight`	1, 2, 3, 5, 7
`gamma`	0, 0.05, 0.1, 0.2, 0.3
`reg_alpha`	0, 0.001, 0.01, 0.1, 1.0
`reg_lambda`	0.5, 1.0, 1.5, 2.0, 3.0

Il confronto tra le due strategie, effettuato sul medesimo seed di cross-validation, ha selezionato `scale_pos_weight` come configurazione vincente in termini di

F1 sul test set. Oltre al vantaggio metrico, tale scelta presenta due vantaggi rilevanti per il caso studio: non altera le istanze di training (i controfattuali Alibi useranno quindi un manifold non contaminato da dati sintetici) e semplifica la pipeline, eliminando l'oversampling esterno. Il modello finale è dunque un XGBoost classifier con `scale_pos_weight` calibrato e gli iperparametri ottimali individuati dalla ricerca randomizzata; gli artefatti prodotti sono il modello serializzato (`models/xgb_model.ubj`) e i dataset pickle di train e test, utilizzati nei notebook di spiegazione per garantire coerenza tra le analisi.

3.2 Performance del modello

Le metriche ottenute dal modello finale sul test set, a soglia di classificazione predefinita (0.50), sono riportate in Tabella 3.2. Il test set è composto da 294 istanze, di cui 247 appartenenti alla classe negativa (dipendenti rimasti) e 47 alla classe positiva (dipendenti usciti).

Tabella 3.2: Prestazioni del modello XGBoost sul test set (soglia = 0,50).

Metrica	Valore
Accuracy	0,823
Precision	0,456
Recall	0,553
F1-score	0,500
AUC-ROC	0,801

L'accuracy dell'82,3% è poco al di sopra della baseline banale del classificatore che predice sempre la classe maggioritaria (circa 83,9%, coincidente con la frequenza della classe negativa), e per questo motivo è una metrica poco informativa in questo contesto. L'informazione rilevante è contenuta nella coppia precision/recall e nella AUC-ROC. In particolare, recall e precision sulla classe positiva (0,553 e 0,456) indicano che il modello individua circa la metà dei dipendenti che effettivamente abbandoneranno, accettando in cambio un tasso di falsi positivi non trascurabile. L'AUC-ROC pari a 0,801 conferma che, indipendentemente dalla soglia, il modello è in grado di separare le due classi in modo nettamente migliore del caso (0,500).

La matrice di confusione in Figura 3.4 rende esplicita la distribuzione degli errori. Il modello commette errori di entrambi i tipi, ma il dato significativo dal punto di vista organizzativo è il numero di *falsi negativi*, cioè di dipendenti realmente in uscita che il modello ha classificato come stabili. Questi casi rappresentano l'oggetto di interesse prioritario per un responsabile HR, perché corrispondono a

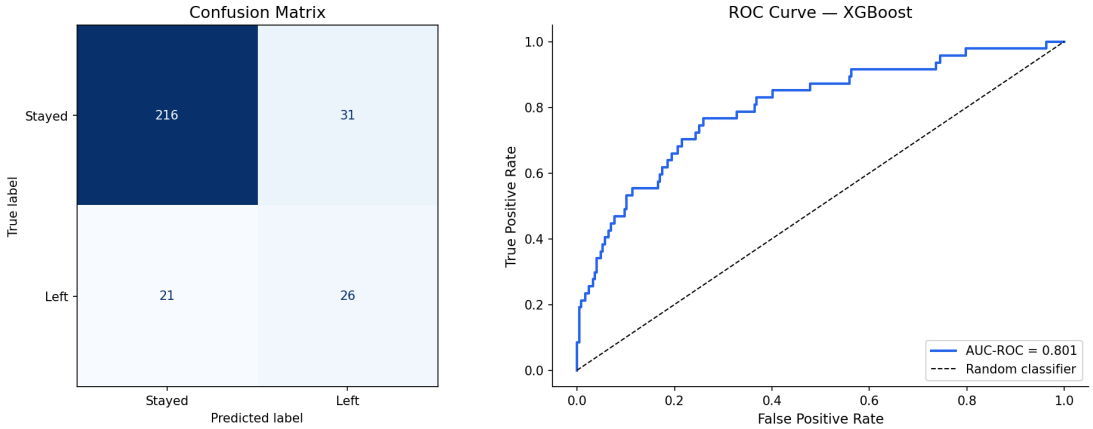

Figura 3.4: Matrice di confusione (sinistra) e curva ROC (destra) sul test set a soglia = 0,50.

situazioni in cui il sistema *non segnala* un rischio che è invece presente: è lì che lo strumento predittivo perde utilità.

3.2.1 Ottimizzazione della soglia

L'asimmetria nel costo degli errori suggerisce di non utilizzare la soglia predefinita 0,50, che bilancia in modo simmetrico precision e recall, ma di spostarla in modo da privilegiare il recall. Dal punto di vista dell'azienda, infatti, un falso positivo (intervenire in via precauzionale su un dipendente che sarebbe rimasto comunque) ha un costo contenuto, riconducibile al tempo speso dall'HR manager e, al più, a un incentivo non necessario. Un falso negativo, al contrario, significa non cogliere un segnale di rischio: il costo include il turnover effettivo, la ricerca del sostituto, l'onboarding e la perdita di capitale umano. Non è quindi ragionevole assumere i due errori come equiparabili.

La Figura 3.5 mostra a sinistra la curva precision–recall del modello e a destra l'andamento di precision, recall e F1 al variare della soglia di classificazione. Sono state confrontate tre soglie:

- **Soglia predefinita** ($t = 0{,}50$): la configurazione standard di `predict`, presentata sopra.
- **Soglia che massimizza F1** ($t \approx 0{,}52$): punto di ottimo rispetto alla metrica di tuning, con uno scostamento minimo rispetto al default.
- **Soglia business-oriented** ($t \approx 0{,}38$): scelta per garantire un recall non inferiore al 66%, a scapito di una precision più bassa.

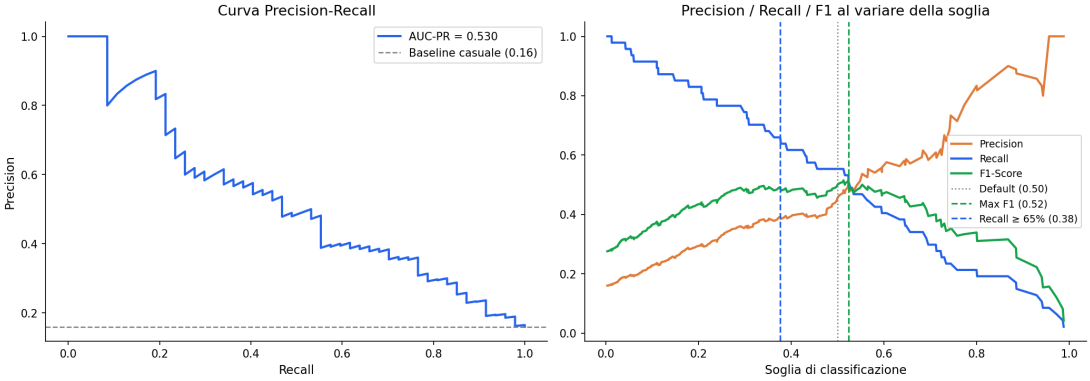

Figura 3.5: Ottimizzazione della soglia: curva precision-recall (sinistra) e andamento di precision, recall e F1 in funzione della soglia (destra).

La soglia business-oriented implementa operativamente il principio secondo cui, nel contesto HR, il recall conta più della precision. L'interpretazione è che il modello, in produzione, dovrebbe essere tarato per essere *prudente*: preferibile segnalare qualche caso in più alla verifica dell'HR manager piuttosto che lasciarsi sfuggire un dipendente realmente a rischio. Questo è un punto di contatto tra la componente predittiva e la componente esplicativa della pipeline: una soglia più bassa aumenta la quantità di istanze per cui si genereranno spiegazioni locali, il che rende ancora più importante disporre di strumenti di XAI capaci di distinguere, *a posteriori*, tra segnalazioni solide e segnalazioni borderline.

3.3 Spiegazioni SHAP

SHAP è stato applicato nella variante `TreeExplainer`, che sfrutta la struttura del modello XGBoost per calcolare in modo esatto i valori di Shapley in tempo polinomiale. Questa scelta offre due garanzie rilevanti: *model-awareness* (i valori sono coerenti con la decisione effettiva del modello, non con un'approssimazione surrogata) e *determinismo* (non essendoci campionamento, ripetizioni successive producono gli stessi risultati). Entrambe le proprietà sono desiderabili in un contesto HR, dove la riproducibilità delle spiegazioni è una precondizione per il loro utilizzo all'interno di processi decisionali.

3.3.1 Importanza globale delle feature

L'aggregazione dei valori SHAP assoluti sull'intero test set fornisce una misura di importanza globale, visualizzata come summary plot in Figura 3.6. Ogni riga rappresenta una feature, ordinata per contributo medio assoluto, e ogni punto un

dipendente; il colore indica il valore della feature, mentre la posizione orizzontale indica l'impatto SHAP sulla predizione.

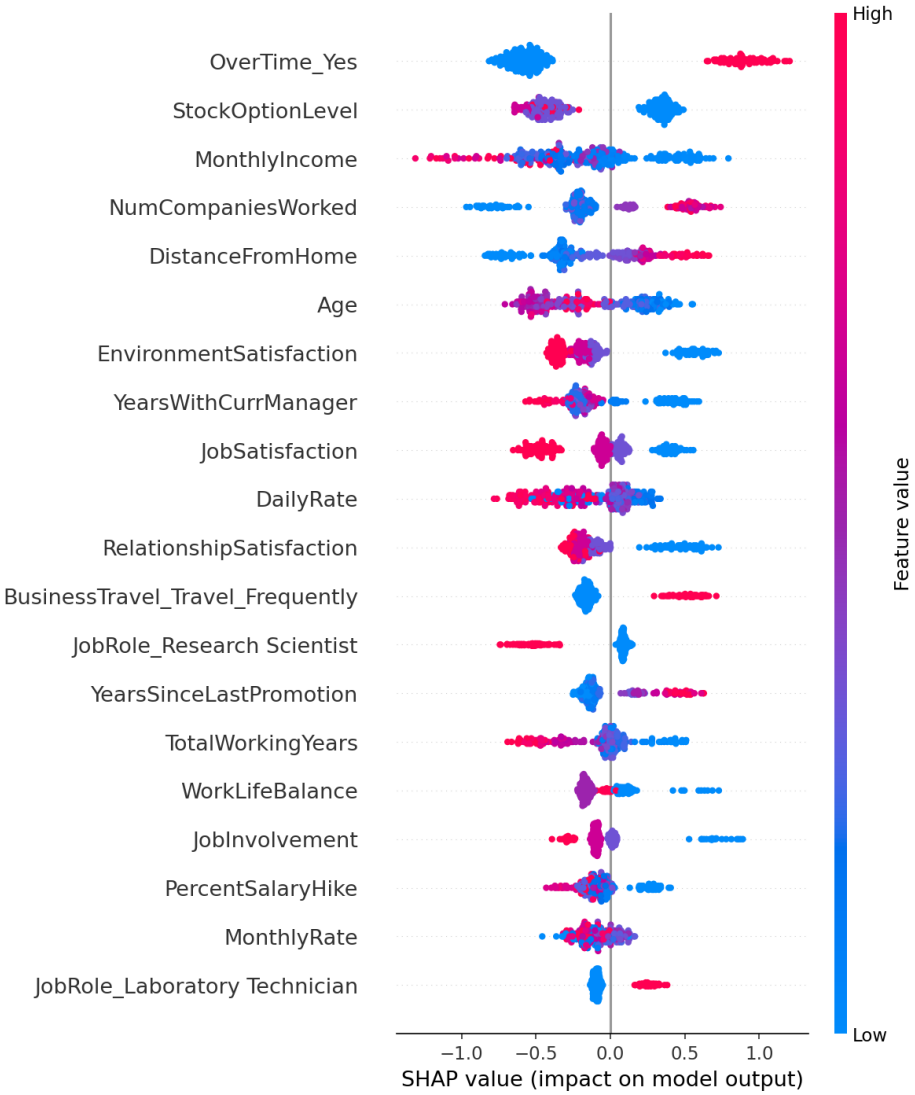

Figura 3.6: SHAP summary plot sul test set: ranking globale delle feature per impatto medio assoluto sulla predizione.

Le feature che emergono nelle prime posizioni sono coerenti con la letteratura HR riportata nel Capitolo 2: `OverTime_Yes`, `MonthlyIncome`, `StockOptionLevel`, `JobSatisfaction` e le variabili di tenure compaiono come i principali driver. La lettura del grafico è duplice: da un lato il summary plot sintetizza *quali* feature pesano sul modello in aggregato, dall'altro rende esplicito il *verso* del loro impatto. Valori alti di `OverTime_Yes` (cioè la presenza di straordinari) si associano a contributi SHAP positivi, spostando la predizione verso la classe "abbandono". Valori alti di `MonthlyIncome` o `StockOptionLevel`, al contrario, si associano a contributi negativi.

Questa vista aggregata è utile per ottenere una comprensione d'insieme del modello, ma non è sufficiente per supportare una decisione su un singolo dipendente: per quest'ultimo scopo occorre passare alle spiegazioni locali.

3.3.2 Tre casi locali: vero positivo, falso positivo, falso negativo

Per illustrare l'utilità operativa di SHAP e per disporre di un paniere comune da confrontare con LIME e con i controfattuali, sono stati selezionati tre dipendenti rappresentativi di situazioni diverse rispetto al modello. La selezione non è casuale: si tratta di un vero positivo con probabilità elevata (Dip. 214), un falso positivo con probabilità elevata (Dip. 223) e un falso negativo (Dip. 240), cioè un dipendente realmente uscito che il modello ha però classificato come stabile. I tre casi permettono di esplorare, rispettivamente, la situazione in cui il modello è corretto e le due modalità principali in cui può sbagliare.

Dipendente 214 — Vero Positivo. Il modello attribuisce a questo dipendente una probabilità di abbandono pari al 96.7%, e in effetti il dipendente ha lasciato l'azienda. Il waterfall plot in Figura 3.7 mostra come si arrivi a tale predizione a partire dal valore atteso. I contributi dominanti sono tutti nella medesima direzione, cioè di rinforzo del rischio: `OverTime_Yes` (presenza di straordinari), valori bassi di `JobSatisfaction` e `EnvironmentSatisfaction`, una tenure recente con il manager corrente, un reddito relativamente basso rispetto al livello di ruolo. Il quadro complessivo è quello di un profilo su cui molteplici fattori di rischio si sommano, ciascuno dei quali potenzialmente *intervenibile* da parte dell'HR (sui turni, sulla mobilità interna, sulla retribuzione). È un caso in cui la predizione è sia corretta sia azionabile: lo strumento funziona.

Dipendente 223 — Falso Positivo. Il modello predice un'elevata probabilità di abbandono ($\approx 86.1\%$), ma il dipendente è in realtà rimasto. Il waterfall plot in Figura 3.8 mostra un profilo per molti versi simile al precedente: presenza di straordinari, stock option assenti, reddito contenuto. La differenza con il caso 214 sta nel fatto che alcune di queste variabili descrivono una condizione transitoria tipica di chi è all'inizio della carriera (giovane, da poco in azienda, retribuzione coerente con il livello), che il modello interpreta come segnale di instabilità ma che non necessariamente preannuncia un abbandono. In altri termini, il modello tende a sovrastimare il peso della componente retributiva e di tenure per i profili più giovani. È un promemoria utile del fatto che, anche quando il modello è "sicuro"

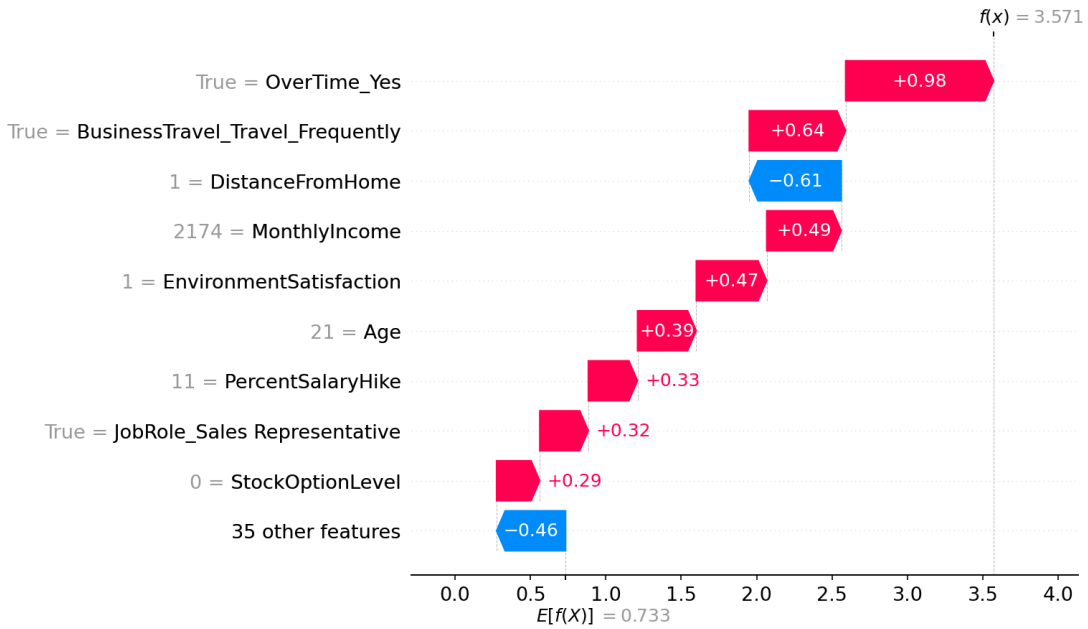

Figura 3.7: SHAP waterfall plot per il Dipendente 214 (vero positivo, $P(\text{Left}) = 0{,}967$).

(probabilità alta), la predizione può essere errata se il contesto del dipendente è al di fuori della distribuzione su cui il modello è stato tarato.

Dipendente 240 — Falso Negativo. Il modello attribuisce a questo dipendente una probabilità di abbandono pressoché nulla ($\approx 0.7\%$), eppure il dipendente ha lasciato l'azienda. Il waterfall plot in Figura 3.9 mostra come quasi tutti i contributi SHAP siano negativi (cioè favorevoli alla permanenza): soddisfazione alta, assenza di straordinari, tenure consolidata, retribuzione elevata. Sulla base delle sole feature osservabili nel dataset il profilo è un profilo di permanenza tipico; il fatto che il dipendente sia invece uscito suggerisce che la decisione sia stata guidata da fattori *non contenuti nel dataset* — un'offerta esterna, una trasformazione personale, un conflitto specifico con il team — che nessuna spiegazione locale basata sulle feature disponibili può recuperare. Il falso negativo non è quindi un errore del metodo di spiegazione ma un *limite intrinseco del dataset*, ed è un caso utile per formare l'utente finale sull'idea che il sistema supporta la decisione umana ma non la sostituisce.

La triade di casi mostra come SHAP sia in grado di fornire una narrazione coerente anche quando il modello sbaglia: la spiegazione locale è parte integrante della diagnosi, non solo della validazione.

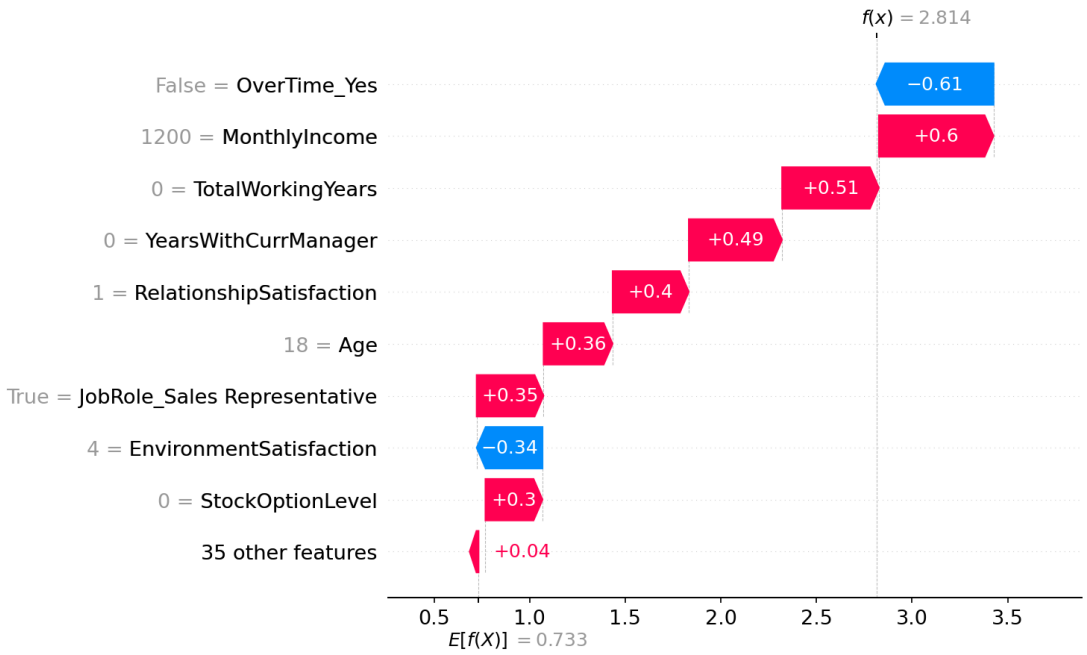

Figura 3.8: SHAP waterfall plot per il Dipendente 223 (falso positivo, $P(\text{Left}) = 0{,}861$).

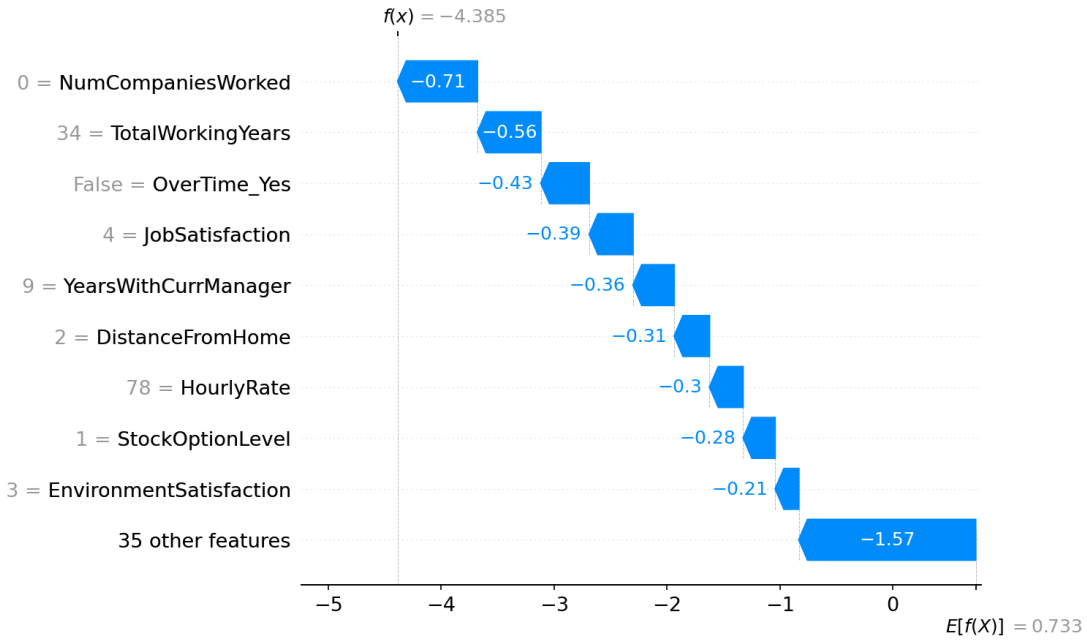

Figura 3.9: SHAP waterfall plot per il Dipendente 240 (falso negativo, $P(\text{Left}) = 0{,}007$).

3.4 Spiegazioni LIME

La seconda famiglia di spiegazioni è stata ottenuta con LIME, nella variante `LimeTabularExplainer` per dati tabulari. La configurazione utilizzata prevede `num_samples=8000` (campioni perturbati per ciascuna spiegazione locale), `discretize_continuous=True` (per ottenere spiegazioni in forma di regole su intervalli di valori, più leggibili per un utente non tecnico) e `random_state=42`. L'explainer è stato inizializzato sul *training set* per assicurare che la stima della distribuzione di ciascuna feature sia coerente con quella usata dal modello in fase di training.

Rispetto a SHAP, LIME è model-agnostic e basato su un surrogato lineare locale: questa scelta comporta maggiore flessibilità ma anche una dipendenza dalla procedura di campionamento. In questa implementazione il tempo di generazione delle spiegazioni sull'intero test set è risultato di circa 39 secondi (294 istanze, $\approx$ 7,43 istanze al secondo): un ordine di grandezza compatibile con un utilizzo interattivo, ma superiore a quello richiesto dal `TreeExplainer` di SHAP.

3.4.1 Importanza globale aggregata

Per ottenere una misura di importanza globale da LIME, i pesi locali di ciascuna feature sono stati aggregati in valore assoluto e mediati sulle 294 istanze del test set. Il ranking risultante è mostrato in Figura 3.10.

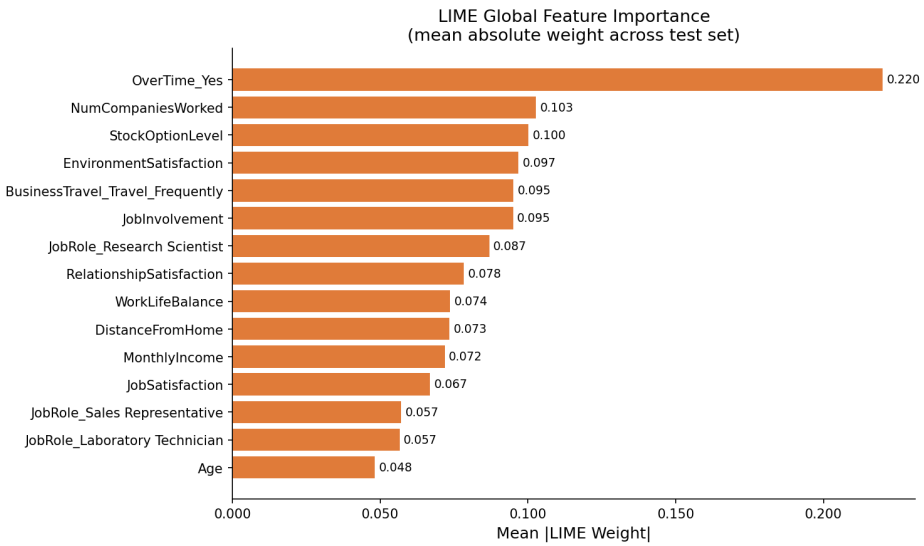

Figura 3.10: Ranking globale aggregato delle feature secondo LIME (media dei pesi in valore assoluto sul test set).

Le prime posizioni del ranking LIME ricalcano in larga parte quelle di SHAP: `OverTime_Yes` è, anche qui, la feature dominante, seguita da `BusinessTravel_Frequently`, `JobRole_Research_Scientist`, `NumCompaniesWorked` e `StockOptionLevel`. Le differenze più evidenti rispetto a SHAP riguardano la discretizzazione: LIME, trasformando le feature continue in intervalli, tende ad amplificare il peso delle variabili categoriche o categoriche ottenute *per binning*, mentre SHAP le tratta in forma continua. Questo spiega in parte la maggiore presenza di feature one-hot nelle prime posizioni del ranking LIME.

3.4.2 Spiegazioni locali sui tre casi

L'analisi locale è stata condotta sugli stessi tre dipendenti discussi nella Sezione 3.3. Le Figure 3.11, 3.12 e 3.13 mostrano le spiegazioni LIME per Dip. 214, 223 e 240 rispettivamente.

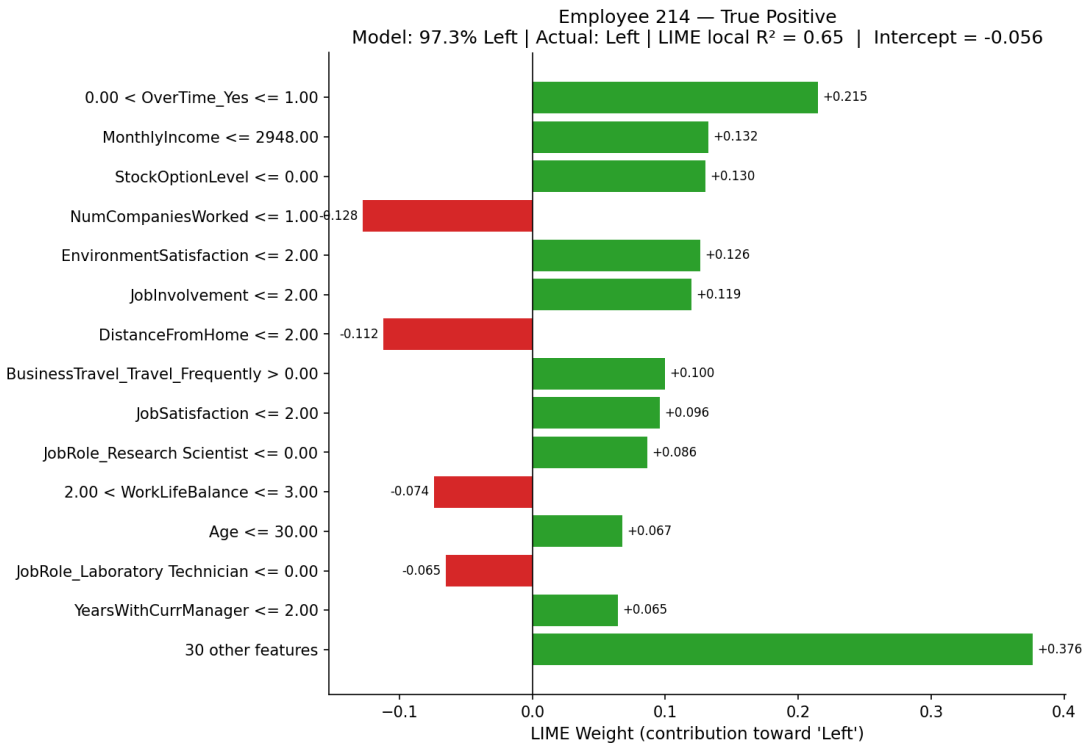

Figura 3.11: LIME local explanation per il Dipendente 214.

Per il Dip. 214 il quadro è sostanzialmente concorde con quello di SHAP: `OverTime_Yes` è il principale driver di rischio, insieme all'assenza di stock option e a un reddito al di sotto di una soglia di riferimento. Per il Dip. 223 LIME attribuisce un ruolo ancor più marcato alla retribuzione e alla bassa tenure, rendendo esplicito il pattern del "profilo giovane" già individuato da SHAP. Per il

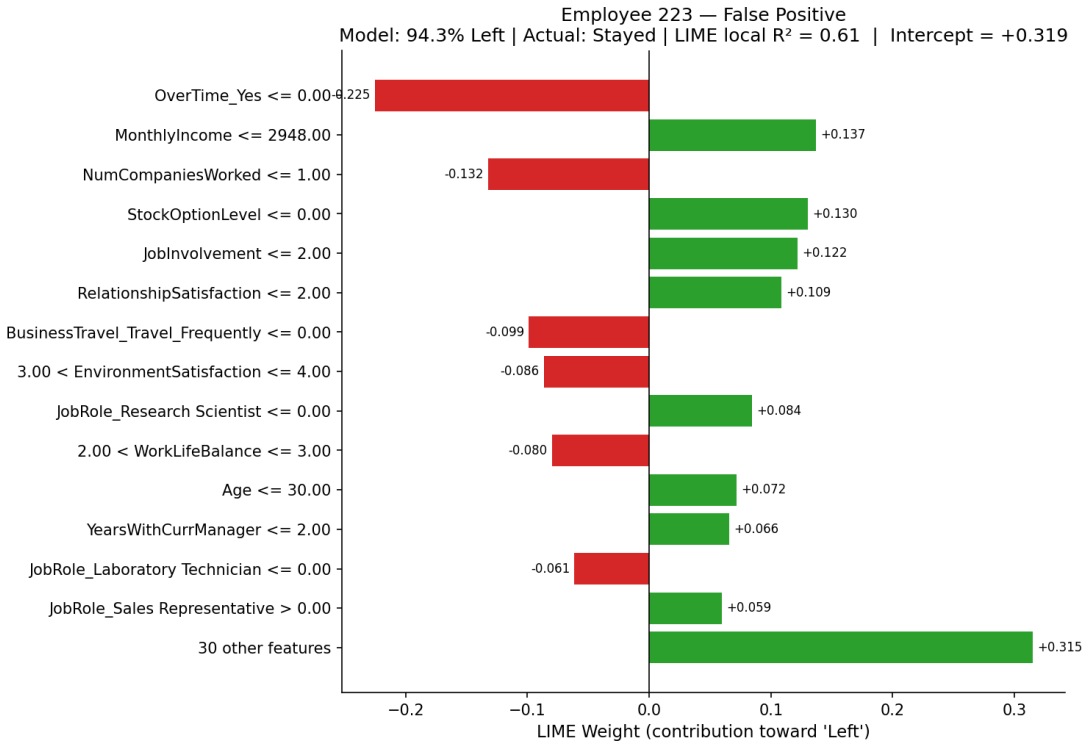

Figura 3.12: LIME local explanation per il Dipendente 223.

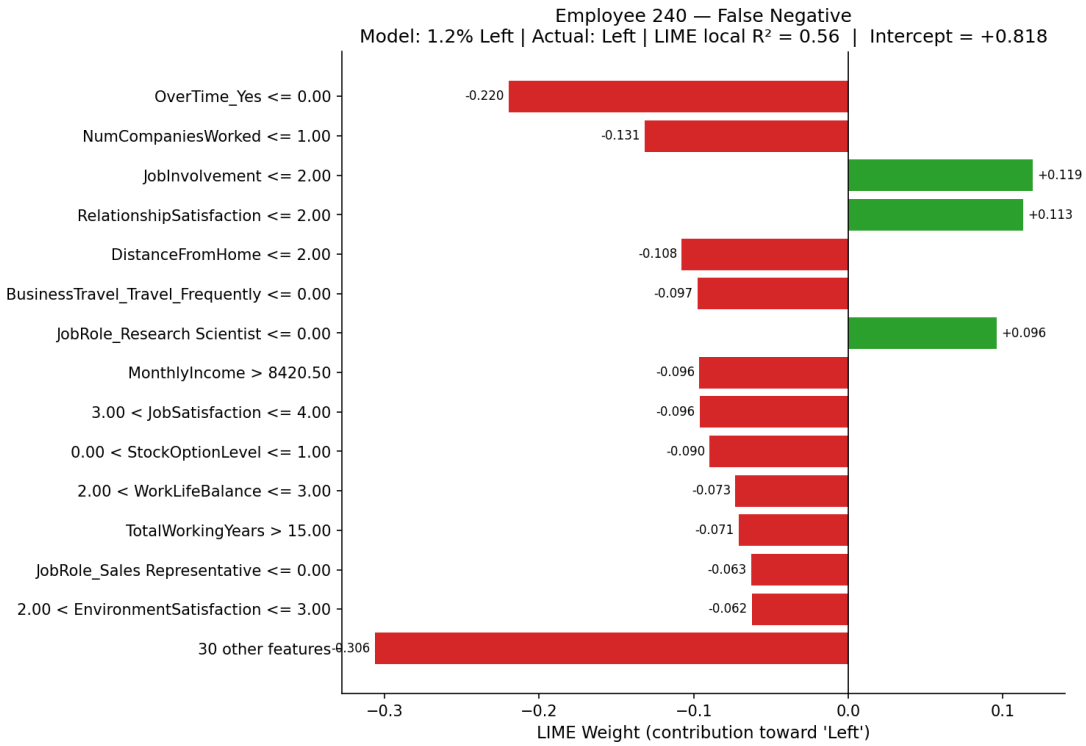

Figura 3.13: LIME local explanation per il Dipendente 240.

Dip. 240 LIME, come SHAP, riporta un quadro di sostanziale stabilità: le feature osservate non contengono segnali di uscita, e il modello di spiegazione riflette fedelmente questa assenza.

Un aspetto da sottolineare è la presenza di discordanze puntuali tra i due metodi: alcune feature che SHAP considera rilevanti perdono peso in LIME e viceversa. Questo non indica un errore di uno dei due metodi, ma la diversa natura delle spiegazioni: SHAP attribuisce in modo additivo la differenza tra la predizione del modello e il suo valore atteso, mentre LIME approssima localmente la superficie di decisione con un modello lineare. In presenza di feature fortemente correlate (come le variabili di tenure) o di effetti non lineari locali, le due prospettive possono produrre ranking diversi pur spiegando lo stesso fenomeno.

3.4.3 Confronto sinottico

Per rendere esplicite le differenze strutturali tra i due framework, la Figura 3.14 riporta un confronto sinottico delle due metodologie lungo gli assi rilevanti per l'uso applicativo.

Confronto SHAP vs LIME — Criteri chiave per HR Analytics

	SHAP	LIME
Scope (ambito)	Globale + Locale	Solo Locale
Tipo	Valori additivi (Shapley)	Modello lineare locale
Approccio	Model-aware (TreeExplainer)	Model-agnostic (perturbazione)
Fedeltà locale	Alta — garanzia teorica	Variabile — dipende da R^2
Fedeltà globale	Alta — consistente	Assente
Stabilità	Alta — deterministico	Media — campionamento casuale
Velocità di calcolo	Veloce (TreeExplainer)	Lenta (8.000 campioni/emp.)
Interpretabilità per l'utente finale	Media — valori numerici	Alta — regole leggibili
Feature importance globale	Sì (mean |SHAP|)	Sì (aggregazione manuale)
Dipendenza dal modello	Tree-based (nativo)	Qualsiasi modello
Gestione interazioni tra feature	Sì — cattura interazioni	No — approssimazione lineare

Figura 3.14: Confronto sinottico SHAP vs LIME: ambito, fedeltà, stabilità, velocità, dipendenza dal modello.

Dal confronto emergono tre indicazioni coerenti con quanto discusso al Capitolo 2: SHAP è preferibile quando si cerca una spiegazione *formalmente fondata* e deterministica di un modello ad albero, a fronte di un'integrazione che richiede un *explainer* specifico per l'architettura; LIME è preferibile quando è importante ottenere spiegazioni sotto forma di regole discretizzate, potenzialmente più vicine al linguaggio di un utente HR, e quando il modello sottostante è sostituibile o non trattabile tramite explainer dedicati. Nel caso studio entrambi i metodi producono,

sugli stessi tre dipendenti, narrazioni sovrapponibili: le discordanze sono locali e riconducibili a caratteristiche note dei due approcci, non a errori.

3.5 Analisi controfattuale (Alibi)

SHAP e LIME rispondono alla domanda *"perché il modello ha deciso così?"*. I controfattuali rispondono invece alla domanda, operativamente più utile per un HR manager, *"cosa dovrebbe cambiare perché il modello decida diversamente?"*. Questa sezione applica la classe `CounterfactualProto` della libreria Alibi ai due dipendenti classificati come ad alto rischio (Dip. 214 e Dip. 223), per verificare in che misura il controfattuale restituisca suggerimenti operativi coerenti con quanto già osservato nelle spiegazioni attribuitive.

3.5.1 Configurazione dell'explainer

L'explainer è stato configurato con la variante basata su prototipi guidati da `k-d tree` (in alternativa all'autoencoder), scelta che riduce il tempo di ottimizzazione e non richiede un modello generativo ausiliario. I parametri principali della funzione obiettivo sono stati fissati come segue: `kappa` = 0,1 (margine della loss di classificazione), `beta` = 0,1 (peso della regolarizzazione L_1, responsabile della *sparsity* del controfattuale), `theta` = 10 (peso del termine di prossimità al prototipo di classe, che garantisce *plausibilità*), `gamma` = 100 (peso della regolarizzazione L_2) e `max_iter` = 500. Il `feature_range` è stato derivato dai valori minimo e massimo osservati sul training set, per evitare che l'ottimizzatore proponga valori al di fuori del dominio empirico. I dati sono stati convertiti in `float32` prima di essere passati all'explainer; le piccole differenze numeriche tra le probabilità riportate qui e quelle di SHAP derivano da questa conversione.

3.5.2 Dipendente 214: una lettura operativa coerente

Il controfattuale per il Dip. 214 porta la probabilità di abbandono stimata dal modello da $\approx 97.3\%$ a $\approx 24.6\%$, un calo che attraversa la soglia di decisione. I cambiamenti suggeriti (Figura 3.15) convergono su un insieme coerente di leve: rimozione degli straordinari (`OverTime`), riduzione della frequenza dei viaggi di lavoro, aumento della permanenza col manager corrente, aumento del coinvolgimento nel ruolo e aumento della frequenza della formazione.

L'aspetto operativamente rilevante è che queste leve sono, in buona parte, *azionabili* da un'organizzazione: una revisione del carico di lavoro, un piano di

Employee 214 (True Positive)
P(Left): 97.3% → 24.6%

Feature	Originale	Controfattuale	Δ
DailyRate	756	746	-9.90
MonthlyIncome	2,174	2,184	+9.90
HourlyRate	99.0	91.5	-7.50
Age	21.0	23.1	+2.10
EnvironmentSatisfaction	1.00	1.50	+0.50
MonthlyRate	9,150	9,150	-0.30
JobSatisfaction	2.00	2.30	+0.30
Education	1.00	1.30	+0.30
YearsInCurrentRole	2.00	1.70	-0.30
JobInvolvement	2.00	2.10	+0.10
RelationshipSatisfaction	3.00	2.90	-0.10
TotalWorkingYears	3.00	3.10	+0.10
TrainingTimesLastYear	3.00	2.90	-0.10
StockOptionLevel	0.00	0.10	+0.10
Department_Research & Development	0.00	0.10	+0.10

Figura 3.15: Controfattuale per il Dipendente 214: feature modificate dall'ottimizzatore con variazione tra valore originale e valore controfattuale.

mobilità interna, un investimento in formazione sono interventi reali di politica del personale. Il controfattuale, in questo caso, non solo concorda con la diagnosi fornita da SHAP e LIME (che indicavano `OverTime` come fattore dominante di rischio), ma estende la spiegazione in direzione prescrittiva: *dato* il profilo del dipendente, quali combinazioni di interventi avrebbero portato la predizione al di sotto della soglia di rischio.

3.5.3 Dipendente 223: un controfattuale che rivela bias del modello

Il controfattuale per il Dip. 223 porta la probabilità stimata da $\approx 94.3\%$ a $\approx 41.6\%$: la riduzione è netta, ma non sufficiente a incrociare la soglia di decisione nella sua accezione più conservativa. Il punto di interesse non è tanto il valore finale quanto la *natura* dei cambiamenti suggeriti (Figura 3.16): l'ottimizzatore propone in particolare un incremento sensibile dell'età (da 18 a circa 30 anni), una riduzione della distanza da casa e un aumento dell'anzianità in azienda e nel ruolo corrente.

Employee 223 (False Positive)
P(Left): 94.3% → 41.3%

Feature	Originale	Controfattuale	Δ
MonthlyIncome	1,200	1,254	+54.4
DailyRate	812	862	+49.7
MonthlyRate	9,724	9,698	-26.0
HourlyRate	69.0	92.3	+23.3
Age	18.0	29.7	+11.7
PercentSalaryHike	12.0	17.3	+5.31
DistanceFromHome	10.0	5.39	-4.61
TrainingTimesLastYear	2.00	6.00	+4.00
JobInvolvement	2.00	4.00	+2.00
WorkLifeBalance	3.00	1.54	-1.46
TotalWorkingYears	0.00	1.07	+1.07
YearsAtCompany	0.00	1.07	+1.07
YearsInCurrentRole	0.00	1.07	+1.07
YearsSinceLastPromotion	0.00	1.07	+1.07
YearsWithCurrManager	0.00	1.07	+1.07

Figura 3.16: Controfattuale per il Dipendente 223: l'ottimizzatore propone modifiche su variabili demografiche e di tenure, rivelando il bias del modello verso i profili giovani.

Queste modifiche hanno due caratteristiche di lettura diverse. Da un lato, rafforzano quanto già osservato nelle sezioni precedenti: il modello attribuisce una quota consistente di rischio al pattern *dipendente giovane, appena assunto, che vive lontano*, e per abbassare la probabilità bisogna di fatto trasformare il dipendente in un profilo diverso. Dall'altro, alcune di queste feature sono *immutabili* o non direttamente azionabili da parte dell'azienda: età, anzianità e distanza da casa non sono leve su cui un HR manager può intervenire. Il controfattuale, in questo caso, non fornisce una prescrizione operativa ma svolge una funzione diagnostica: rende visibile un potenziale bias del modello e segnala che la predizione originaria, pur essendo "spiegabile", andrebbe trattata con cautela prima di generare un'azione concreta.

3.5.4 Leve azionabili vs fattori immutabili

I due casi, presi insieme, mostrano che il valore di una spiegazione controfattuale dipende in modo decisivo dalla natura delle feature che entrano nella proposta di modifica. Le feature che possono essere considerate *leve azionabili* in un contesto HR — tipicamente `OverTime`, `StockOptionLevel`, `TrainingTimesLastYear`, `BusinessTravel` — producono controfattuali traducibili in azioni manageriali concrete. Le feature *strutturali o immutabili* — tipicamente `Age`, `TotalWorkingYears`, `YearsAtCompany`, `DistanceFromHome` — producono controfattuali che non sono prescrittivi ma che hanno comunque valore come *test di robustezza* del modello: la loro comparsa in una spiegazione controfattuale segnala che la predizione è sensibile a caratteristiche su cui l'intervento è impossibile o eticamente problematico.

Questa distinzione, assente nelle spiegazioni attributive di SHAP e LIME, è il contributo specifico dei controfattuali al flusso di analisi: non si limita a dire cosa il modello sta guardando, ma forza l'utente a interrogarsi su cosa il modello *dovrebbe* poter guardare in un processo decisionale responsabile.

3.6 Dashboard

Capitolo 4

Discussione

4.1 Sintesi dei risultati

Il filo che attraversa il caso studio del capitolo precedente si può ricondurre alla tesi formulata nell'Introduzione: una predizione di rischio, per quanto accurata, non è azionabile in mancanza di una spiegazione che indichi su quali fattori intervenire e con quale grado di fiducia. Il confronto condotto sulle stesse istanze mostra che SHAP, LIME e i controfattuali non costituiscono alternative in competizione ma rispondono a tre domande distinte, che insieme compongono un triangolo diagnostico al servizio del responsabile HR. In assenza di tale triangolazione, l'utente si troverebbe nella condizione poco funzionale descritta dalla letteratura sulla sfiducia verso gli algoritmi osservati sbagliare anche una sola volta Dietvorst, Simmons e Massey, "Algorithm aversion: people erroneously avoid algorithms after seeing them err."

La prima dimensione, coperta da SHAP, risponde alla domanda *"perché il modello ha deciso così?"*. Come emerso nella Sezione 3.3, il `TreeExplainer` produce un'attribuzione additiva, deterministica e coerente con la decisione effettiva del modello, sia a livello globale (Figura 3.6) sia a livello della singola istanza (Figura 3.7). La seconda dimensione, coperta da LIME, risponde alla domanda *"quali regole semplici approssimano la decisione?"*: il surrogato lineare locale con feature discretizzate (Sezione 3.4, Figura 3.11) traduce la decisione del modello in soglie e condizioni più vicine al linguaggio di un utente non tecnico, a prezzo di una dipendenza dal campionamento e di una fedeltà puramente locale. La terza dimensione, coperta dai controfattuali Alibi, risponde alla domanda operativamente più incisiva per un HR manager, *"cosa dovrebbe cambiare perché la predizione cambi?"*: l'esito non è un ranking di fattori ma un insieme di modifiche minime alle feature del dipendente capaci di spostare la predizione al di là della soglia di

decisione (Sezione 3.5, Figure 3.15 e 3.16).

La complementarità delle tre prospettive diventa evidente leggendo trasversalmente i tre casi selezionati nelle sezioni precedenti. Per il Dipendente 214, vero positivo ad alta probabilità, i tre framework convergono: SHAP e LIME individuano gli stessi fattori dominanti (straordinari, soddisfazione e retribuzione) e il controfattuale conferma che agendo proprio su quelle leve la predizione scende al di sotto della soglia. In questo caso la spiegazione ha valore di *supporto all'intervento*, perché indica contemporaneamente dove guardare e su cosa agire. Per il Dipendente 223, falso positivo ad alta probabilità, l'allineamento dei tre framework svolge invece una funzione diagnostica sul modello: SHAP e LIME mostrano che il rischio stimato è dominato da caratteristiche riconducibili al profilo giovane e da poco assunto, e il controfattuale rivela che per abbassare la predizione l'ottimizzatore deve intervenire su variabili strutturalmente immutabili come l'età e l'anzianità. La convergenza dei tre metodi segnala che la predizione, pur essendo spiegabile, poggia su un pattern problematico e dunque non andrebbe usata come base di azione. Per il Dipendente 240, falso negativo, SHAP e LIME producono spiegazioni coerenti di permanenza: nessuno dei due metodi, per costruzione, può recuperare informazione assente dalle feature osservate. Qui il limite che le spiegazioni locali rendono visibile è del dataset, non del metodo esplicativo.

Tirando le fila, il caso studio non elegge un "vincitore" tra i tre framework. Mostra piuttosto che il valore per il responsabile HR non risiede nella singola probabilità restituita dal modello ma nell'ecosistema che la accompagna: un'attribuzione fondata per la diagnosi, una rappresentazione a regole per la comunicazione, un controfattuale per la prescrizione. In questa chiave, il modello XAI-assistito si configura come strumento di supporto alla decisione e non di sua sostituzione: una distinzione che la sezione successiva riprende per circoscrivere l'ambito di validità delle conclusioni.

4.2 Limiti del caso studio

La lettura dei risultati proposta nella Sezione 4.1 acquista significato solo se accompagnata da una dichiarazione esplicita dei limiti entro cui vale. Tali limiti riguardano la natura del dataset, la sua dimensione, l'insieme delle feature disponibili e le proprietà intrinseche dei tre metodi esplicativi adottati.

Il primo limite riguarda la natura del dataset utilizzato. L'*IBM HR Employee Attrition* è un dataset didattico, costruito a scopo di benchmark e non derivato da un'organizzazione reale: la distribuzione delle feature e la relazione tra queste e il

target rispecchiano un'impostazione pensata per la ricerca e la formazione, non le specificità di un contesto aziendale operativo. Di conseguenza, ogni conclusione sulla *performance predittiva* del modello o sulla *composizione dei driver* osservati non può essere trasferita senza cautela a un'organizzazione concreta, pena la confusione tra una proprietà del dataset e una proprietà del fenomeno IBM Watson Analytics, *IBM HR Analytics Employee Attrition & Performance*.

Il secondo limite è dimensionale. I numeri richiamati nella Sezione 3.1 — popolazione ridotta, sbilanciamento marcato, test set che contiene una frazione contenuta di eventi positivi — hanno due conseguenze concrete. Sulle metriche aggregate di prestazione introducono una varianza campionaria elevata, che rende le stime puntuali di precision, recall e F1 indicative più che stabili. Sulle spiegazioni locali incide invece la rarità dei positivi: le narrazioni costruite sui tre dipendenti selezionati sono plausibili e coerenti, ma la loro *rappresentatività* statistica rispetto alla classe positiva resta limitata proprio dalla dimensione di quest'ultima. L'analisi qualitativa è dunque robusta come illustrazione del comportamento dei tre framework, non come base per inferenze quantitative sulla popolazione.

Il terzo limite riguarda l'insieme delle feature. Il dataset copre dimensioni anagrafiche, retributive, di ruolo, di tenure e di soddisfazione, ma non include variabili di natura organizzativa e relazionale — clima interno, stile di leadership, offerte esterne ricevute dal dipendente, rete informale di relazioni, eventi personali — che la letteratura identifica come determinanti spesso decisivi del turnover. Il caso del Dipendente 240, falso negativo con un profilo di permanenza "pulito" su tutte le feature osservate, è l'illustrazione più diretta di questo limite: nessun metodo XAI, per quanto sofisticato, può recuperare informazione non presente nei dati di input. Questo vincolo non è specifico del caso studio ma struttura in modo più generale la People Analytics fondata esclusivamente su dati strutturati Isson e Harriott, *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent*.

Il quarto limite è di natura metodologica e riguarda i tre framework stessi, in coerenza con quanto già osservato nel capitolo precedente. La collinearità rilevata tra le variabili di tenure (Sezione 3.1) fa sì che SHAP e LIME distribuiscano l'importanza tra proxy dello stesso costrutto, rendendo più difficile isolare una singola leva di intervento. LIME, in quanto basato su campionamento perturbativo, presenta una variabilità residua anche quando il seed è fissato, e produce un surrogato lineare la cui fedeltà è garantita solo localmente. I controfattuali, infine, possono proporre modifiche su feature strutturalmente immutabili (età, anzianità, distanza da casa), come emerso per il Dipendente 223 nella Sezione 3.5: in quel

caso la spiegazione mantiene un valore diagnostico sul modello, ma perde valore prescrittivo sull'azione HR.

Presi insieme, questi limiti non invalidano il contributo illustrativo del caso studio ma ne circoscrivono l'ambito: le conclusioni tratte valgono come dimostrazione della complementarità dei tre metodi su un benchmark noto, non come stima delle loro prestazioni in contesti organizzativi reali. È su questa consapevolezza che poggia la sezione seguente, dedicata alle implicazioni per la pratica HR.

4.3 Implicazioni per la pratica HR

I risultati e i limiti discussi nelle sezioni precedenti acquistano pieno significato solo se tradotti in indicazioni per la pratica del responsabile HR. Questa sezione colloca il triangolo diagnostico all'interno di un workflow operativo, ne discute i rischi legati alla fiducia nel sistema e affronta le implicazioni etiche e normative dell'impiego di modelli predittivi nel contesto del lavoro.

4.3.1 Dal segnale all'azione: il workflow XAI-assistito

La letteratura sulla XAI applicata identifica cinque profili distinti di destinatari delle spiegazioni — esperti di dominio, soggetti impattati, regolatori, manager e sviluppatori — ciascuno con esigenze diverse in termini di profondità, formato e scopo della spiegazione Barredo Arrieta et al., "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI". Nel contesto HR, il responsabile del personale appartiene al profilo dell'*esperto di dominio*: non possiede necessariamente competenze di modellazione statistica, ma dispone di conoscenza contestuale sul dipendente che il modello non ha. La spiegazione deve quindi essere *actionable*, cioè capace di colmare il divario tra il segnale computazionale e la decisione operativa Barredo Arrieta et al., "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI".

Il workflow che emerge dal caso studio si articola in tre fasi. Nella prima, il modello segnala i profili a rischio attraverso la soglia business-oriented discussa nella Sezione 3.2: una soglia calibrata per privilegiare il recall produce un insieme di segnalazioni da sottoporre a triage qualitativo. Nella seconda fase, le spiegazioni attributive (SHAP e LIME) consentono al responsabile HR di comprendere *perché* il modello consideri quel dipendente a rischio, distinguendo tra segnalazioni solide e segnalazioni borderline. Nella terza fase, il controfattuale traduce la diagnosi in prescrizione, indicando su quali leve intervenire per modificare la predizione. Il

valore delle spiegazioni locali rispetto alle sole importanze globali è strutturale: le seconde descrivono il modello in aggregato, le prime descrivono il singolo dipendente e abilitano un intervento mirato.

Questa articolazione riflette quanto osservato nelle organizzazioni che utilizzano effettivamente la XAI in produzione: il decisore umano non è un fruitore passivo ma svolge un ruolo di validazione critica, confrontando la spiegazione con la propria conoscenza del contesto e decidendo se confermare, approfondire o annullare la segnalazione del modello Bhatt et al., "Explainable Machine Learning in Deployment".

4.3.2 Rischi dell'adozione: algorithm aversion e automation bias

L'introduzione di un sistema predittivo nel processo decisionale HR espone l'organizzazione a due polarità disfunzionali opposte. Da un lato, la letteratura documenta il fenomeno dell'*algorithm aversion*: la tendenza a rifiutare il supporto algoritmico dopo aver osservato anche un singolo errore, indipendentemente dalla performance complessiva del sistema Dietvorst, Simmons e Massey, "Algorithm aversion: people erroneously avoid algorithms after seeing them err." Dall'altro, studi successivi hanno mostrato il fenomeno speculare dell'*algorithm appreciation*: in assenza di errori visibili, le persone tendono a dare più peso ai consigli algoritmici rispetto a quelli umani, e tale fiducia persiste anche in ambiti soggettivi Logg, Minson e Moore, *Algorithm Appreciation: People Prefer Algorithmic To Human Judgment*. I due fenomeni coesistono e dipendono dal contesto: l'avversione emerge dopo la visione di un errore, mentre l'apprezzamento è la risposta predefinita in assenza di feedback negativi.

In termini più generali, la tassonomia classica dell'interazione umano-automazione distingue tra *misuse* (sovraffidamento che porta a non rilevare errori del sistema), *disuse* (sottoutilizzazione dovuta a scarsa fiducia) e *abuse* (implementazione del sistema senza considerare le conseguenze sulla prestazione umana) Parasuraman e Riley, "Humans and Automation: Use, Misuse, Disuse, Abuse". Il caso studio illustra entrambe le polarità a rischio: un responsabile HR che si affidi acriticamente al punteggio avrebbe attivato un intervento non necessario sul Dipendente 223 (falso positivo); un responsabile che diffidi sistematicamente del modello avrebbe ignorato anche il Dipendente 214 (vero positivo). Il ruolo della XAI è restituire al decisore umano gli elementi per esercitare un giudizio informato, riducendo sia il rischio di misuse sia quello di disuse attraverso la trasparenza della spiegazione.

4.3.3 Bias algoritmici e fairness

Un modello predittivo apprende i pattern presenti nei dati di addestramento, inclusi quelli che riflettono disuguaglianze strutturali. Feature apparentemente neutre possono fungere da *proxy* per caratteristiche protette: la letteratura mostra come variabili quali il quartiere di residenza, la distanza casa-lavoro o la rete di relazioni sociali possano predire con elevata accuratezza l'appartenenza a gruppi demografici, consentendo al modello di discriminare senza mai consultare direttamente i dati sensibili Barocas e Selbst, "Big Data's Disparate Impact". Inoltre, quando i dati storici riflettono decisioni umane già viziate da pregiudizi, il modello formalizza quelle discriminazioni come regole oggettive, trasformando le disuguaglianze del passato in profezie che si autoavverano Barocas e Selbst, "Big Data's Disparate Impact".

Nel caso studio, il Dipendente 223 offre una micro-illustrazione di questo rischio: il modello attribuisce un rischio elevato a un profilo giovane con bassa tenure, e il controfattuale rivela che l'unica via per abbassare la predizione è "invecchiare" il dipendente. Le spiegazioni locali fungono qui da strumento di *audit*: rendono visibile su quali feature il modello si appoggia e consentono di identificare pattern potenzialmente discriminatori prima che si traducano in azioni. Questa funzione diagnostica è coerente con le strategie di mitigazione documentate nella letteratura sui tool HR, che includono il monitoraggio dell'impatto disparato e la rimozione o riduzione del peso delle feature correlate ad attributi protetti Raghavan et al., "Mitigating Bias in Algorithmic Hiring: Evaluating Claims and Practices".

4.3.4 Quadro normativo: GDPR e AI Act

Il quadro normativo europeo impone vincoli specifici all'uso di sistemi decisionali automatizzati nel contesto lavorativo. L'Articolo 22 del GDPR riconosce il diritto dell'interessato a non essere soggetto a decisioni basate unicamente su trattamenti automatizzati che producano effetti giuridici o incidano in modo analogo e significativo sulla persona *Regolamento (UE) 2016/679 del Parlamento Europeo e del Consiglio — Articolo 22: Processo decisionale automatizzato relativo alle persone fisiche, compresa la profilazione*. Nei casi in cui tali decisioni siano consentite, il regolamento prescrive misure di tutela che includono il diritto all'intervento umano, a esprimere la propria opinione e a contestare la decisione Goodman e Flaxman, "European Union Regulations on Algorithmic Decision-Making and a "Right to Explanation"".

Il dibattito in letteratura si concentra sulla portata dell'obbligo di fornire "informazioni significative sulla logica coinvolta". Un'interpretazione restrittiva limita tale obbligo a una descrizione ex ante della funzionalità del sistema; un'interpretazione funzionale sostiene invece che, poiché i modelli di machine learning sono deterministici, una spiegazione che non permetta all'interessato di comprendere come i propri dati abbiano influenzato la decisione non può considerarsi significativa Selbst e Powles, "Meaningful information and the right to explanation". In questa seconda ottica, le spiegazioni controfattuali sono state proposte come la forma più compatibile con il requisito del GDPR, perché indicano le condizioni minime sotto le quali la decisione sarebbe stata diversa senza richiedere la disclosure dell'intero modello Wachter, Mittelstadt e Russell, "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR".

Il Regolamento (UE) 2024/1689 (AI Act) introduce un ulteriore livello di disciplina. L'Articolo 6, paragrafo 2, in combinazione con l'Allegato III, punto 4, classifica esplicitamente i sistemi di intelligenza artificiale utilizzati per il recruitment, la gestione del rapporto di lavoro, le decisioni su promozioni e cessazioni come sistemi *ad alto rischio* "Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)". Per tali sistemi, l'Articolo 13 impone obblighi di trasparenza — istruzioni d'uso che includano caratteristiche, limiti di prestazione e misure di supervisione — e l'Articolo 14 prescrive che siano progettati per essere effettivamente sorvegliati da persone fisiche dotate della competenza, formazione e autorità necessarie per comprenderne i limiti e, se del caso, ignorarne o annullarne l'output "Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)".

4.3.5 Human-in-the-loop come requisito di governance

Le considerazioni precedenti convergono su un principio trasversale: il modello XAI-assistito non è un sistema decisionale autonomo ma uno strumento che amplifica la capacità analitica del responsabile HR, a condizione che resti inserito in un ciclo di supervisione umana effettiva. Il valore della spiegazione non è un fine in sé, ma il mezzo attraverso cui tale supervisione diventa informata e capace di individuare tanto i segnali affidabili quanto i pattern problematici. In questa prospettiva, la XAI non risolve il problema della fiducia nel modello ma lo trasforma: da una scelta binaria (fidarsi o meno della predizione) a una

valutazione graduata, fondata sulla qualità e sulla coerenza della spiegazione che la accompagna.

Capitolo 5

Conclusioni e sviluppi futuri

Il presente lavoro si proponeva tre obiettivi: fornire un quadro teorico sull'applicazione della XAI alla previsione del turnover, confrontare tre framework esplicativi — SHAP, LIME e le spiegazioni controfattuali — analizzandone fondamenti, proprietà e limiti, e infine illustrare, attraverso un caso studio, come ciascun framework risponda a domande differenti poste dal responsabile HR.

Il quadro teorico sviluppato nel Capitolo 2 ha collocato la XAI all'intersezione tra l'evoluzione della People Analytics verso approcci predittivi e i vincoli di trasparenza imposti dal contesto decisionale HR e dal quadro normativo europeo. L'analisi dei tre framework ha mostrato che SHAP, LIME e i controfattuali non si pongono in alternativa ma operano su piani complementari: l'attribuzione additiva di SHAP garantisce coerenza con la decisione del modello e consente una diagnosi fondata; il surrogato lineare di LIME traduce la decisione in regole accessibili a un utente non tecnico; il controfattuale indica le condizioni minime sotto cui la predizione cambierebbe, abilitando il passaggio dalla diagnosi alla prescrizione.

Il caso studio condotto sul dataset IBM HR Employee Attrition (Capitolo 3) ha reso tangibile questa complementarità. L'analisi trasversale dei tre dipendenti selezionati ha mostrato che il valore operativo delle spiegazioni non risiede nella singola tecnica ma nella loro triangolazione: la convergenza dei tre metodi rafforza la fiducia nella segnalazione e nell'intervento proposto, mentre la divergenza — come nel caso del falso positivo dominato da caratteristiche strutturali — segnala un pattern problematico del modello e suggerisce cautela nell'azione. Il modello XAI-assistito si configura così come strumento di supporto alla decisione, non di sua sostituzione: la spiegazione restituisce al responsabile HR gli elementi per esercitare un giudizio informato, riducendo sia il rischio di sovraffidamento acritico sia quello di rifiuto sistematico del supporto algoritmico.

La conclusione principale del lavoro è dunque che la capacità predittiva di

un modello di machine learning, nel contesto HR, acquista reale valore operativo solo quando è accompagnata da un ecosistema esplicativo capace di rispondere simultaneamente alle domande *perché*, *come* e *cosa fare*. La XAI non risolve il problema della fiducia nel modello, ma lo trasforma da scelta binaria a valutazione graduata, fondata sulla qualità e sulla coerenza delle spiegazioni che accompagnano la predizione.

5.1 Sviluppi futuri

I limiti discussi nel Capitolo 4 suggeriscono tre direzioni di sviluppo che potrebbero estendere e consolidare i risultati del presente lavoro.

La prima direzione riguarda l'applicazione su dati aziendali reali. Il dataset IBM HR, pur essendo un benchmark consolidato, è di natura didattica e non riflette le specificità di un contesto organizzativo operativo. L'adozione dei tre framework esplicativi su dati provenienti da un'organizzazione concreta consentirebbe di verificare se la complementarità osservata nel caso studio si mantiene anche in presenza di distribuzioni più complesse, di un numero maggiore di osservazioni e di dinamiche di turnover legate a fattori contestuali non presenti nel benchmark.

La seconda direzione concerne l'integrazione di feature qualitative. Il caso del Dipendente 240, falso negativo con un profilo di permanenza coerente su tutte le variabili osservate, ha reso evidente che i dati strutturati da soli non esauriscono i determinanti del turnover. L'inclusione di variabili derivate da survey sul clima organizzativo, da analisi del sentiment delle comunicazioni interne o da indicatori relazionali potrebbe arricchire sia la capacità predittiva del modello sia la qualità delle spiegazioni locali, fornendo al responsabile HR leve di intervento oggi non visibili.

La terza direzione riguarda l'estensione ad altri modelli predittivi. Il caso studio ha impiegato un singolo algoritmo (XGBoost) e la letteratura ha mostrato che le spiegazioni prodotte da SHAP e LIME possono variare in funzione dell'architettura del modello sottostante. Un confronto sistematico delle spiegazioni generate su modelli differenti — reti neurali, ensemble di diversa natura, modelli lineari regolarizzati — permetterebbe di valutare la stabilità e la generalizzabilità delle conclusioni esplicative al variare della scelta modellistica, rafforzando o circoscrivendo la portata del triangolo diagnostico proposto.

Appendice A

Appendici

A.1 Elenco completo delle feature del dataset IBM HR

La Tabella A.1 riporta le 35 feature originali del dataset IBM HR Employee Attrition, con indicazione del tipo, del range o dei valori ammessi e di una breve descrizione. Le feature contrassegnate con † sono state rimosse in fase di preprocessing in quanto costanti o identificative.

Tabella A.1: Feature del dataset IBM HR Employee Attrition.

Feature	Tipo	Range/Valori	Descrizione
Age	int	[18, 60]	Età del dipendente
Attrition	cat	Yes, No	Variabile target: abbandono
BusinessTravel	cat	Non-Travel, Rarely, Frequently	Frequenza dei viaggi di lavoro
DailyRate	int	[102, 1499]	Tariffa giornaliera
Department	cat	HR, R&D, Sales	Dipartimento di appartenenza
DistanceFromHome	int	[1, 29]	Distanza casa-lavoro (km)
Education	int	[1, 5]	Livello di istruzione (1=sotto diploma, 5=dottorato)

Continua nella pagina successiva

Feature	Tipo	Range/Valori	Descrizione
EducationField	cat	6 valori	Campo di studi
EmployeeCount†	int	1	Costante (rimossa)
EmployeeNumber†	int	[1, 2068]	Identificativo (rimosso)
EnvironmentSatisfaction	int	[1, 4]	Soddisfazione ambiente (1=bassa, 4=alta)
Gender	cat	Female, Male	Genere
HourlyRate	int	[30, 100]	Tariffa oraria
JobInvolvement	int	[1, 4]	Coinvolgimento nel lavoro
JobLevel	int	[1, 5]	Livello gerarchico
JobRole	cat	9 valori	Ruolo ricoperto
JobSatisfaction	int	[1, 4]	Soddisfazione lavorativa
MaritalStatus	cat	Divorced, Married, Single	Stato civile
MonthlyIncome	int	[1009, 19999]	Reddito mensile ($)
MonthlyRate	int	[2094, 26999]	Tariffa mensile
NumCompaniesWorked	int	[0, 9]	Numero di aziende precedenti
Over18†	cat	Y	Costante (rimossa)
OverTime	cat	Yes, No	Presenza di straordinari
PercentSalaryHike	int	[11, 25]	Incremento salariale (%)
PerformanceRating	int	[3, 4]	Valutazione della prestazione
RelationshipSatisfaction	int	[1, 4]	Soddisfazione relazionale
StandardHours†	int	80	Costante (rimossa)
StockOptionLevel	int	[0, 3]	Livello di stock option
TotalWorkingYears	int	[0, 40]	Anni totali di esperienza
TrainingTimesLastYear	int	[0, 6]	Sessioni di formazione nell'ultimo anno
WorkLifeBalance	int	[1, 4]	Equilibrio vita-lavoro
YearsAtCompany	int	[0, 40]	Anni nell'azienda attuale
YearsInCurrentRole	int	[0, 18]	Anni nel ruolo attuale
YearsSinceLastPromotion	int	[0, 15]	Anni dall'ultima promozione

Continua nella pagina successiva

Feature	Tipo	Range/Valori	Descrizione
YearsWithCurrManager	int	[0, 17]	Anni con il manager attuale

A.2 Spazio degli iperparametri e configurazione del modello

La Tabella A.2 riporta lo spazio di ricerca completo esplorato dalla `RandomizedSearchCV` per il modello XGBoost. La configurazione della ricerca è la seguente:

- Numero di iterazioni: 150
- Cross-validation: `StratifiedKFold` con 5 fold (`shuffle=True`, `random_state=42`)
- Metrica di scoring: F1-score sulla classe positiva
- Strategia di bilanciamento selezionata: `scale_pos_weight` (rapporto tra classe negativa e positiva sul train set)
- Seed di riproducibilità: `random_state=42`

Tabella A.2: Spazio di ricerca completo degli iperparametri.

Iperparametro	Valori esplorati	Descrizione
`n_estimators`	100, 200, 300, 500, 700	Numero di alberi
`max_depth`	3, 4, 5, 6, 7, 8	Profondità massima per albero
`learning_rate`	0.01, 0.03, 0.05, 0.08, 0.1, 0.15	Tasso di apprendimento
`subsample`	0.6, 0.7, 0.8, 0.9, 1.0	Frazione di campioni per albero
`colsample_bytree`	0.5, 0.6, 0.7, 0.8, 0.9, 1.0	Frazione di feature per albero
`min_child_weight`	1, 2, 3, 5, 7	Peso minimo in un nodo foglia
`gamma`	0, 0.05, 0.1, 0.2, 0.3	Riduzione minima di loss per split
`reg_alpha`	0, 0.001, 0.01, 0.1, 1.0	Regolarizzazione L1
`reg_lambda`	0.5, 1.0, 1.5, 2.0, 3.0	Regolarizzazione L2

Lo spazio combinatorio totale è pari a $5 \times 6 \times 6 \times 5 \times 6 \times 5 \times 5 \times 5 \times 5 = 3\,375\,000$ configurazioni; la ricerca randomizzata ne ha campionate 150, corrispondenti allo 0,004% dello spazio. Il modello finale, selezionato sulla base dell'F1 sul test set, è composto da 500 alberi.

Bibliografia

Boushey, Heather e Sarah Jane Glynn. *There Are Significant Business Costs to Replacing Employees*. Center for American Progress report. https://americanprogress.org/article/sig business-costs-replacing-employees/. 2012.

Work Institute. *2024 Retention Report: Employee Turnover Insights and Trends in 2023*. Retirement of thousands of US employees: exit interview analysis. 2024. URL: `https://info.workinstitute.com/2024-retention-report`.

Kuhn, Peter e Lizi Yu. "How Costly Is Turnover? Evidence from Retail". In: *Journal of Labor Economics* 39.2 (2021), pp. 461–496.

Price, Alan. *The Cost of Employee Turnover*. BrightHR blog. Summarizes Oxford Economics/Unum data for UK. 2020. URL: `https://www.brighthr.com/articles/culture-and-performance/staff-turnover/employee-turnover-costs/`.

CIPD. *The True Cost of Hiring in 2025*. Recruitment Robin summary of CIPD data. 2025. URL: `https://recruitmentrobin.com/the-true-cost-of-hiring-in-2025-what-every-employer-needs-to-know/`.

Elevo HR. *Le vrai coût du turn-over et de la perte des talents*. Elevo Blog. 2023. URL: `https://www.elevo.fr/blog/le-vrai-cout-du-turn-over-et-de-la-perte-des-talents`.

Isson, Jean Paul e Jesse Harriott. *People analytics in the era of big data: changing the way you attract, acquire, develop, and retain talent*. Apr. 2016. URL: `http://catalogimages.wiley.com/images/db/jimages/9781119050780.jpg`.

Poynton, Shannon et al. *2026 Global Human Capital Trends. From tensions to tipping points: Choosing the human advantage*. Consultato il 10 aprile 2026. Deloitte Insights, 2026. URL: `https://www.deloitte.com/insights`.

Schweyer, Allan. "Predictive analytics and artificial intelligence in people management". In: *Incentive Research Foundation* (2018), pp. 1–18.

Dietvorst, Berkeley J, Joseph P Simmons e Cade Massey. "Algorithm aversion: people erroneously avoid algorithms after seeing them err." In: *Journal of experimental psychology: General* 144.1 (2015), p. 114.

Regolamento (UE) 2016/679 del Parlamento Europeo e del Consiglio — Articolo 22: Processo decisionale automatizzato relativo alle persone fisiche, compresa la profilazione. General Data Protection Regulation (GDPR). GU L 119 del 4.5.2016. 2016. URL: https://eur-lex.europa.eu/eli/reg/2016/679/oj.

Molnar, Christoph. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. 2025. URL: https://christophm.github.io/interpretable-ml-book/.

Roscher, Ribana et al. "Explainable Machine Learning for Scientific Insights and Discoveries". In: *IEEE Access* 8 (2020), pp. 42200–42216. DOI: 10.1109/ACCESS.2020.2976199.

Lundberg, Scott M. e Su-In Lee. "A Unified Approach to Interpreting Model Predictions". In: *31st Conference on Neural Information Processing Systems (NIPS 2017)*. Long Beach, CA, USA, 2017. URL: https://arxiv.org/pdf/1705.07874.

Lundberg, Scott M., Gabriel Erion et al. "Explainable AI for Trees: From Local Explanations to Global Understanding". In: *arXiv preprint arXiv:1905.04610* (2019). URL: https://arxiv.org/abs/1905.04610.

Ribeiro, Marco Tulio, Sameer Singh e Carlos Guestrin. ""Why Should I Trust You?": Explaining the Predictions of Any Classifier". In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 1135–1144. DOI: 10.1145/2939672.2939778.

Wachter, Sandra, Brent Mittelstadt e Chris Russell. "Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR". In: *Harvard Journal of Law & Technology* 31.2 (2017), pp. 841–887.

Miller, Tim. "Explanation in Artificial Intelligence: Insights from the Social Sciences". In: *Artificial Intelligence* 267 (2019), pp. 1–38.

Van Looveren, Arnaud e Janis Klaise. "Interpretable Counterfactual Explanations Guided by Prototypes". In: *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*. Lecture Notes in Computer Science. Springer, 2021, pp. 650–665.

Doumard, Emmanuel et al. "A Comparative Study of Additive Local Explanation Methods Based on Feature Influences". In: *Proceedings of the Workshop on Explainable and Interpretable Machine Learning (XIML)*. 2022. URL: https://ceur-ws.org/Vol-3130/paper4.pdf.

IBM Watson Analytics. *IBM HR Analytics Employee Attrition & Performance*. Kaggle. Dataset fittizio creato da data scientist IBM a scopo didattico e di ben-

chmark. 2017. URL: https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset.

Barredo Arrieta, Alejandro et al. "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI". In: *Information Fusion* 58 (2020), pp. 82–115.

Bhatt, Umang et al. "Explainable Machine Learning in Deployment". In: *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT* '20)*. 2020.

Logg, Jennifer M., Julia A. Minson e Don A. Moore. *Algorithm Appreciation: People Prefer Algorithmic To Human Judgment*. Working Paper 17-086. Harvard Business School, 2018.

Parasuraman, Raja e Victor Riley. "Humans and Automation: Use, Misuse, Disuse, Abuse". In: *Human Factors* 39.2 (1997), pp. 230–253.

Barocas, Solon e Andrew D. Selbst. "Big Data's Disparate Impact". In: *California Law Review* 104 (2016), pp. 671–732.

Raghavan, Manish et al. "Mitigating Bias in Algorithmic Hiring: Evaluating Claims and Practices". In: *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. 2020, pp. 469–481.

Goodman, Bryce e Seth Flaxman. "European Union Regulations on Algorithmic Decision-Making and a "Right to Explanation"". In: *AI Magazine* 38.3 (2017), pp. 50–57.

Selbst, Andrew D. e Julia Powles. "Meaningful information and the right to explanation". In: *International Data Privacy Law* 7.4 (2017), pp. 233–242.

"Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)". In: *Official Journal of the European Union* (2024). URL: http://data.europa.eu/eli/reg/2024/1689/oj.

Ringraziamenti